

TeX Gyre Termes TeX Gyre Heros Latin Modern Mono
=1

BioMed QAgent

面向生物医学研究的多源数据智能采集与分析系统

赛题方向 阿里云 AI Scientist 赛题
团队名称 BioMed-QAgent 项目组
学校 北京航空航天大学
日期 2026 年 8 月

参赛作品名称	BioMed QAgent：面向生物医学研究的多源数据智能采集与分析系统
参赛选题	赛道2-方向1A
参赛作品简介	系统采用“开放式推理与确定性数据处理分权”的设计：Qwen 等 LLM 驱动的 Pi Agent 负责理解研究目标、发现候选来源、检查可用执行路线并提交声明式数据需求；TypeScript Dataset Core 负责来源资产登记、已注册解析器执行、规范化、多源整合、质量门禁、人在回路和正式发布。系统不将 Agent 工作区中的临时 CSV 视为任务完成，而以包含数据表、Schema、Provenance、Audit、Validation 和内容摘要的、追加式发布且读取时按摘要重验的 Publication 作为正式结果。支持多种静态数据产品，并提供动态 Family 协议处理静态注册表无法表达的多表拓扑。来源文件通过 SourceAsset、SHA-256、Provider revision evidence 和 SourceLocator 进入证据链；不确定的字段映射、未知单位和低置信度抽取可以触发可持久化的人在回路请求；任务中断后可依据事件、操作摘要和 checkpoint 恢复，而不要求模型重新解释已经确认的数据变换。
参赛作品使用Qwen大模型及AI技术说明	本作品未将 Qwen 模型写死在配置中，而是提供 API key 配置方法，允许用户自选包含 Qwen API key 在内的 LLM 作为主 Agent。实验部分（第五章）中，Qwen 系列承担 gold8 正式发布（qwen3.8-27B）、图表理解链路（DashScope Qwen-VL）与全谱系对抗验证（qwen3.7/3.8 各档位）；另以 DeepSeek-V4-Flash 作为评测主力，验证系统的模型无关性。使用 DashScope API key 时，系统可调用 Qwen-VL 理解页面图像进行数据提取。
宣传视频链接/其他作品相关文件链接	https://github.com/Lidozs55/BioMed-QAgent

目录

1 引言

1.1 真实科研中数据查找与整合的具体不足

在生物医学研究中，“找到数据”并不是搜索到一个网页链接。一个可用于下游分析的数据集至少需要同时回答：数据对应什么实体和样本、来自哪个版本、如何从原文件变成当前字段、不同来源能否在同一粒度上合并、哪些值存在冲突，以及哪些判断仍需研究者确认。现有工作流程主要存在以下不足。

第一，数据来源分散且检索接口异构。同一研究问题可能同时涉及 PubMed 或 Europe PMC 中的论文、GEO/GDC/Xena 中的表达数据、ClinVar/GWAS Catalog 中的变异证据、PDB/UniProt 中的蛋白信息，以及论文附件或网页下载。不同平台的查询语言、分页方式、访问限制、版本标识和返回格式不同。研究者往往能找到“相关页面”，但难以证明是否覆盖了应查来源、是否遍历了分页、是否遗漏补充材料。

第二，可读信息不等于可计算数据。论文中的 HTML、XML、PDF 表格、扫描图、折线图和补充 XLSX 需要不同解析方法。复杂表格还可能包含合并单元格、跨页表头、脚注、单位信息和缩写。视觉模型可以读取图表，但模型输出本身具有非确定性，若不保留页码、边界框、模型身份、提示版本和置信度，就难以复核。

第三，多源数据的语义不自动一致。相同列名可能代表不同测量语义，不同列名也可能代表同一概念：基因、探针、变异、化合物和样本各自有不同标识体系。以表达数据为例，probe-level 与 gene-level 具有不同的行粒度，原始强度、归一化表达量和对数值不能仅凭列名直接拼接。以生物活性数据为例，同一化合物的跨库 identity、实验类型和活性单位需要显式交叉映射与冲突记录。

第四，人工复制整理难以复现。常见流程是在浏览器、Excel、脚本和聊天窗口间复制内容。即使最终得到 CSV，也常缺少原始文件摘要、检索条件、字段映射、被拒绝行、冲突处理和处理程序版本。后续发现错误时，研究者难以判断应修改哪一步，只能重新整理。

第五，一次性问答无法承担长流程状态。科学数据任务可能因下载、权限、人工确认或服务故障跨越多个会话。普通问答把中间状态留在上下文窗口中，一旦超时或重启，模型容易重复下载、改变处理方式或遗忘用户指令。

1.2 相关工作与差异定位

先简要回顾四类直接相关的工作。检索方面，PubMed、Europe PMC 等文献平台与 GEO、GDC、PDB、UniProt、ClinVar、ChEMBL 等专业数据库提供标识稳定、字段规范的入口，但跨库研究仍需手工组合不同查询条件并下载文件；通用网页搜索能发现未被 API 暴露的页面和附件，但通常来说，搜索引擎的页面排名不一定能够反映数据质量，网页内容也不能直接作为证据使用。数据解析方面，规则解析器对固定格式更可复现，却难以覆盖布局复杂的非结构化内容；OCR 与支持视觉的大语言模型（vLLM）更加泛用，但识别精度有限。整合与溯源方面，传统抽取—转换—加载（Extract-Transform-Load, ETL）擅长映射固定输入与输出结构，但难以覆盖运行时才确定的开放式来源集合。LLM 辅助方面，检索增强生成、工具调用与 ReAct 类方法让模型能在回答前搜索外部信息并调用工具，但直接让模型生成或改写正式数据会面临幻觉、不可重复与长流程状态脆弱等问题。

与上述研究脉络并行，三类工程系统已各自成熟。本系统与它们的逐项差异见表 ??：

表 1.1：与相邻工程系统的差异对照

相邻系统	已提供	本作的差异
LangChain / AutoGen 等 Agent 框架	模型规划与工具执行的通用分离	分权收进数据信任边界，三点可检验：(1) 只有注册解析器（Adapter）能进入 Core 的固定八阶段；(2) 无法证明正确的结果一律拒绝（拿不准就拒绝，fail closed）；(3) 正式完成以不可变的发布物为证据，而非执行器返回值；普通 Run 仍允许无发布物结束，统一终态发布门仍是待办

相邻系统	已提供	本作的差异
DocETL / Palimpzest 等声明式 LLM 数据管线	以自然语言规格表达的语义算子与管线自动优化	LLM 算子与最终产物之间没有信任边界，“完成”只是“流水线跑完”。本系统的模型只产生候选与规格，模型提议的表结构必须通过预检和闭世界准入（只接受有注册规则或绑定证据的变更）才被采纳（创新点二）
W3C PROV / FAIR / OpenLineage	溯源关系的表达模型、数据可查找可复用的评价原则、跨工具 lineage 事件标准	只表达和观测“溯源应该长什么样”，不生成、不校验、也不阻止无溯源发布。本系统三点可检验：(1) 溯源是数据流强制产生的副产物；(2) 按清单逐件验证（SLSA 式），缺少溯源覆盖即验证失败；(3) 每次读取都重算摘要，不匹配就拒绝展示
Temporal / Airflow 等持久化工作流引擎	检查点、重试、可恢复执行与人工任务节点	恢复的是通用流程状态，人工任务不与证据绑定。本系统的人工确认（HIL）恢复时要求证据摘要与任务身份一致（见 ?? 节），高风险证据类型（动态发布、图表证据等）的发布验收不可绕过，修正后发布新版本（supersedes 关系）并保留旧版本历史，而不是覆盖

把上述四点合并起来看，本系统的定位更接近一个“可信科学数据编译器”：自然语言研究需求是输入，具有表结构、来源、质量记录和发布回执的数据产品是输出。在这一过程中，模型承担需求理解、来源探索与规格选择等开放性语义工作，Dataset Core 独占正式数据变换与发布权，用一条强约束的证据闭环覆盖整个数据生命周期，使研究者能始终回答“数据从哪里来、如何变成现在这样、哪些地方仍不确定”。

1.3 本系统希望解决的问题

BioMed-QAgent 的目的不是“替研究者得出科学结论”，而是完成赛题明确提出、位置更上游的一步：把自然语言研究目标转换为一份结构化科学数据产品，它可以继续分析、追溯来源、检查质量，并能根据反馈加以修正。

系统试图解决四个连续问题，四者依次覆盖“Agent 外部工作→Dataset Core 确定性流水线”的主链路：

1. 根据研究目标定位合适的论文、数据库、附件、表格或图像数据（Agent 侧的需求编译与来源发现）；
2. 把异构载体解析为明确表结构和行粒度下的规范记录（Core 的解析、规范化阶段）；
3. 在不掩盖缺失、重复、单位差异和身份冲突的前提下完成多源整合（Core 的兼容、整合、派生阶段）；
4. 将每一步的来源、输入摘要、处理版本、质量判断和人工修正一起发布，使结果能被验证和复用（Core 的校验、发布阶段与可持久化的人工确认）。

系统有意不把科研分析和结论生成纳入正式完成标准。这样既符合赛题 1A 的任务边界，也避免将“数据是否正确”与“模型解释是否听起来合理”混在一起。相应地，系统的工程投入集中在赛题要求的核心链路——来源发现与覆盖、异构解析、清洗整合、图表提取与全链路溯源——其逐维度实证与边界见第五章。

1.4 研究问题与数据需求

本文要解决的核心问题是：用户以自然语言提出的研究需求，能否被系统可靠地转换为一份定义明确、过程可控、结果可复核的数据交付？回答这一问题需要明确两件事：一是系统应从需求中提取并固定哪些关键信息，二是一份合格的结果必须满足哪些条件。

用户输入最初只是一段自由文本，可能存在多种解读方式。为了避免歧义，系统并不试图穷尽地形式化用户的全部科学意图——那样做既不可能，也没有必要——而是只固定那些“一旦改变，数据产品的含义就会随之变化”的关键选择。这些选择共有十项，共同构成本次执行的数据集规格，在实现中对应数据集执行规格（DatasetExecutionSpec）结构：

表 1.2: 数据集规格的十项关键选择

选择	含义	改变意味着什么
数据产品类别	本次需要哪一类数据产品	决定交付物的整体形态
行粒度	表中每一行代表什么观测或统计单位	决定哪些行可以合并、哪些必须拆表
目标表结构	交付表包含哪些字段及其组织方式	决定字段级映射、类型与校验规则
实体集合	分析涉及的对象是谁、范围多大	决定采集与筛选的边界
队列与筛选条件	按什么标准纳入或排除样本	改变结果的总体与可比性
来源与采集绑定	数据取自哪个外部库或文件、采用何种访问方式	决定可溯源性
规范化配置	采用哪套标准化流程及参数	决定值语义的一致性
合并策略	多个来源出现重叠或冲突信息时按什么规则取舍	决定冲突审计的内容
验证配置	用哪些规则和阈值判断质量是否达标	决定发布门槛
输出格式	最终以什么格式交付	决定下游可用性

明确这十项之后，同一份需求就可以被反复执行、逐项核对和事后审计，不会因表述含糊而产生不同的结果。

相应地，系统的交付物也不是一张孤立的数据表。一个合格的候选结果必须同时包含六类信息：

- 数据本身：可以是单张表，也可以是由主外键关联的多张表组成的集合；
- 表结构：各表的字段结构与约束；
- 溯源信息：数据来自哪些来源，每条记录在原始数据中如何定位；
- 审计记录：完整保留处理过程中被丢弃的数据、检测到的冲突以及所做的修正；
- 验证结果：各项质量门的判定结论；
- 文件清单：逐一登记正式交付的文件及对应的 SHA-256 校验值。

候选结果只有在通过全部质量门检查后，系统才生成正式发布版。正式发布按追加方式落盘、读取时按发布清单重验文件摘要，检出意外或不完整篡改即拒绝展示；它不提供同一 OS 账户完全重写文件系统时的密码学防篡改。这样设计的目的在于：使用者不仅能直接基于表格开展分析，还能逐项查证数据的来源与处理过程，保证交付物可追溯、可复现。

1.5 主要贡献与创新点

本文将实际完成的功能归纳为三个创新点，均以同一机制为基底：从来源字节到发布物的全链路内容寻址——逐文件 SHA-256 与读取时重验，即贯穿第四章八阶段流水线的证据链。三点均对照现有产品的实际缺口表述。

创新点一：任务完成绑定唯一可验证产物，而非模型自报。主流 Agent 框架（LangGraph、AutoGen、OpenAI Agents 等）以模型自报、对话结束或工具返回值界定“完成”，不设“产物哈希重验失败即拒绝展示”的正式门[?, ?, ?]。本系统把正式完成定义为唯一可达的不可变发布物；普通 Run 仍可在无发布物时结束，统一 end-of-run 发布门仍属待办，当前依靠提示词、状态分层与 supervisor 约束。完成契约写入系统提示，运行时逐回合注入“尚无正式发布物”“仍有工具在执行”等进度真相，终态一律拿不准就拒绝（fail closed）。这是对“执行幻觉”（自报完成、产出为空壳或伪造行）的结构性对策——对抗验证中 qwen3.7-plus 曾三轮谎报完成，r4 占位符空壳是内容筛查落地前的唯一穿透、此后未再发生（详见 ?? 节；机制见 ?? 节）。

创新点二：表结构可运行时申请进入，但准入权始终在 Core。声明式 LLM 数据管线（DocETL、Palimpzest）中，LLM 生成的算子与表结构在进入最终产物前没有信任边界，其校验停留在准确度层面，最终输出也只是普通文件[?, ?]。本系统允许未注册的多表拓扑“申请进入”，但须通过语义闭包预检（输入角色、可物化性、输出精确闭合），候选字节在隔离区逐文件重算摘要，且变换方在代码级无法选择校验、评估与发布模块——开放输入不扩大写入权限（实证见 gold7 预检 11 次结构化拒绝后的正式闭环；机制见第四章 B 路线）。

创新点三：人工确认与证据绑定、可恢复、留版本史。工作流引擎（Temporal、Airflow）的人工任务节点不绑定证据摘要，Temporal 官方文档亦提示开发者自行校验审批数据[?]。本系统的审批请求携带覆盖

其对象的证据摘要，响应与任务身份不符即拒绝恢复；需要发布验收的场景（动态发布、图表证据、浏览器证据接受）不可绕过且强制人工；修正经 supersedes 关系形成新版本而非覆盖旧产物（详见 ?? 节）。

2 问题定义

2.1 任务边界

本系统支持的核心任务是：给定医学研究对象和数据需求，发现并采集一个或多个科学数据来源，将其转换为统一的单表或多表结构，保留来源和处理记录，并输出便于后续分析的 CSV 数据产品。

相应地，本系统不把下列事项作为正式交付承诺：自动提出并验证科学假设、替代领域专家判断数据科学含义、对研究结果给出医学结论、保证互联网范围的绝对查全、将模型抽取值自动升级为高可信事实。

这些事项的完成标准要么依赖未封闭的科学判断（假设验证与医学结论），要么超出可证明范围（绝对查全），要么会把低可信抽取误升级为事实；系统对这些事项的处置方式是结构化阻断与随产物交付的边界披露（实例见第五章案例）。

2.2 设计目标

1. 可用性：输出为明确表结构下的 CSV 单表或多表，可直接进入 R/Python/统计软件或后续知识图谱流程（由发布阶段的发布清单统一承载）。
2. 可追溯性：每个正式来源绑定文件摘要和来源身份；记录尽可能携带可返回原载体的定位信息（由采集阶段的来源资产与定位信息承载）。
3. 可靠性：解析、规范化、整合和发布由注册代码执行；缺失、重复、冲突和单位问题显式记录（由注册解析器与确定性流水线承载）。
4. 可修正性：需要研究者判断时暂停并请求结构化输入；反馈后从同一任务状态恢复（由可持久化的人工确认承载）。
5. 可恢复性：下载和长流程操作可重试；已完成且摘要一致的阶段可从检查点复用（由事件日志与检查点承载）。
6. 能力诚实性：工作区暂存、正式候选和已发布产品分层；系统不能以对话措辞替代发布证据（由三层产物模型承载）。
7. 可扩展性：固定数据家族覆盖成熟高频场景，动态数据家族在严格协议下表达未注册多表拓扑（由数据家族注册表与动态规格协议承载）。

系统重点防范以下失败：来源 URL 或版本漂移；下载中断或内容类型错误；字段映射模糊；单位、尺度或行粒度不兼容；重复与冲突被静默覆盖；模型输出无证据；任务重启后重复或改变处理；过期执行晚到发布；正式文件被修改后仍被展示。这些失败模式对应的机制与实测拦截记录一览见 ?? 节。

这些问题并非都能被自动“修复”。项目的目标是自动解决确定性问题，对无法安全判断的问题进行阻断、降级、记录或请求人工输入。

3 Core 外部：系统组成与 Agent 设计

BioMed 的整体设计遵循一个核心原则：开放式理解交给 LLM，正式数据改变交给确定性 Dataset Core，两者通过声明式规格与事件日志耦合，使“找到什么、怎么解析、如何清洗、从哪里来、输出成什么”都可检查、可回溯。主图给出整体分层与赛题评分维度的对照；本章描述 Core 之外的部分，Dataset Core 内部的固定流水线在第四章展开。




图 3.1: BioMed QAgent 主架构图

3.1 系统组成总览

系统由五个部分组成，Dataset Core 居于核心，是唯一的数据信任边界：

- 前端任务工作台：需求对话、实时步骤流（思考、工具调用、进度）、人工确认对话框（批量审核、结构化修正）、发布物浏览与溯源/置信度下钻。
- 模型服务（外部依赖）：Qwen 主对话模型与 Qwen-VL 图表提取经 DashScope 调用；模型只提供理解、候选与提取，不产出正式数据值。
- Agent 层（Pi 智能体 + 可恢复运行环境）：完成意图理解、来源发现与评估、证据收集，并把结果固化为数据集执行规格提交 Core（唯一入口）；全程以事件日志留痕，支持实时推送、检查点续跑与下载断点续传。
- 数据源与采集通道：内置生命科学库（GEO、GDC、Xena、PDB、PubChem、Reactome、ChEMBL、UniProt 等）、文献与受控 API（PubMed、GWAS Catalog、dbSNP、MGnify、openFDA、PMC 等）、用户扩展的声明式 HTTP 数据（需凭据授权）、本地导入文件与本地缓存（已验证下载按内容摘要复用）。研究者可指定偏好来源，但正式获取只由 Core 执行。
- 人类在环：证据绑定的三档审批贯穿系统内外——每类审批对象可配置为人工审批 / LLM 初审（仅不通过项上报人工）/ 显式自动通过，初审不通过或模型调用失败一律回退人工，发布边界（动态发布、图表证据等高风险类型）强制人工、发布验收不可绕过（机制见 ?? 节）。

3.2 三层产物模型

系统把结果分为三层：

1. 工作区暂存结果：搜索下载、模型阅读、探索脚本或 provisional CSV，可帮助 Agent 工作，但不具有正式可信语义。
2. Core 候选结果：来源已登记，处理步骤有操作收据，候选表具有表结构、溯源和验证报告，但仍可能因质量门或人工确认未完成而不可发布。

3. 正式发布结果：通过发布门后形成追加式、读取时按发布清单重验的发布目录，包含发布清单、数据表、表结构、溯源、审计、验证与文件 SHA-256。产品界面只应把这一层视为任务完成。

该分层是项目区别于“Agent 生成 CSV”的关键，也是 ?? 节创新点一的机制基础。它使“文件存在”“候选有效”和“正式可交付”成为三个可检查状态。这三层直接服务赛题“清洗整合可靠”与“输出格式可用”两项标准：只有到达第三层的对象才携带表结构、溯源与验证，下游脚本可以依赖其结构而无须信任聊天输出。

3.3 研究需求编译

Agent 首先把用户问题中的目标实体、数据类型、样本或队列条件、必需字段、期望粒度和输出要求整理为结构化需求；随后必须执行一次“路线检查”，查看当前注册表支持哪些数据家族、表结构、来源和解析器组合，以及动态路线可以直接绑定的数据提供者。

需求编译不是一次自由文本改写，而是形成数据集执行规格（DatasetExecutionSpec）的过程。服务器对规格做交叉校验：数据家族与表结构是否已注册、行粒度与目标实体层级是否一致、每个来源绑定对应的提供者/解析器/参数是否合法、规范化/合并/校验配置是否在白名单内、输出格式是否受支持、多表输入的角色关系是否闭合——校验不通过即阻断或要求修正。

如果注册表能精确表达需求，Agent 走静态路线；如果静态结构不匹配，但所有输入都能由 Core 的提供者获取（或已是任务拥有的来源资产），可走动态路线。两条路线都无法闭合时，系统只交付明确标记为暂存（provisional）的结果并列出缺失的正式能力，绝不伪装成正式发布。

3.4 候选来源发现

来源发现由 Agent 的查询策略和专用工具共同完成，采用多路召回：文献 API、专业数据库、补充材料归档与通用网页搜索并行，同一主题从多个互补通道交叉验证。当前代码覆盖文献、表达组学、变异、药物与生物活性、蛋白与通路、临床试验、微生物组及通用网页等通道。发现阶段的目标是确定候选编号（accession）、论文、数据集、附件和下载入口，并理解其字段与范围。

为回答“是否在问题子领域内查全”，系统设计了 SourceCoverage 覆盖证据：由 Core 生成检索计划与覆盖结果、在数据契约中定义稳定的通信结构，记录检索计划（绑定来源、提供者、解析器与参数）、按绑定记账的采集回执与行数（解析/规范化保留/拒绝、排除原因）、检索观察（查询式、状态、结果数与请求上限）和汇总（universe 总数、成功/失败/未尝试、集成行数）；覆盖只在预先定义的源集合（spec_source_bindings）内计算，Agent 文本不得自行宣称“全网查全”。当前静态与注册式路线随发布清单交付不可变审计产物，Agent 可经 inspect_source_coverage 消费；Dynamic Family 路线尚不产出该报告。完整检索 filters、时间窗口、请求/成功页数与原始/去重/选定计数仍是遗留项（见 ?? 节）。

3.5 Agent 的自主决策面

Agent 与 Core 的分工可以概括为：Agent 是数据产品的设计者与承包商，负责开放式的研究决策；Core 是监理与验收方，负责把设计确定性地建成、可验证地交付。Agent 的自主性体现在数据产品生产的各个决策点上（表 ??），Core 约束的是这些决策进入正式数据的通道，而不是决策本身。

表 3.1: Agent 的自主决策清单

决策点	Agent 自主决定	Core 的约束
检索与来源	在文献 API、专业数据库、补充材料归档、网页等通道间组合查询策略，评估与排序候选来源，决定采集对象与顺序	正式采集由注册提供者执行，来源字节登记为内容寻址的任务资产
执行路线	路线检查后选择静态家族或动态路线；静态结构不匹配时，从零设计多表结构（FamilySpec：表、主外键、角色映射、来源绑定）	规格须通过预检与闭世界准入；候选字节经隔离区逐文件重算摘要
规格迭代	依据预检的结构化错误自主修正设计，直至收敛（gold7 实测 11 次拒绝-修正循环）	拒绝理由逐字段点名、可操作；不通过即不执行

决策点	Agent 自主决定	Core 的约束
质量与修正	自检已发布版本的缺陷并发起换版（gold7 v1→v2）；决定降级、阻断与续跑策略	换版经 supersedes 关系保留历史；发布验收（高风险类型）由人工确认
数据值	提出字段映射、单位换算与抽取值的候选	正式数据值由注册的解析、归一与整合操作产出；动态路线中 digest-bound 变换产生的候选字节须经闭世界准入、Validation、B3、ProductAssessment 与 Publisher 逐级把关，或经注册规则与人工确认采纳

以 gold7 的一次任务为例：Agent 自主选择动态路线、设计三表结构与外键、组合 GWAS Catalog/补充材料/dbSNP 三个来源、经 11 轮预检迭代修正规格，发布后又自检 v1 的统计列缺陷并发起 v2 换版——没有任何一步来自人工逐步指令。系统的约束作用于这些决策的可验证性：无法证明正确的候选进不了正式数据，能证明正确的决策全部由 Agent 自主完成。

3.6 LLM 使用方法与上下文工程

本节展开 Agent 侧（Dataset Core 外部）LLM 使用与上下文工程的实现细节，对应 ?? 节的创新点一；其中证据上下文控制（?? 节）与第四章验证阶段的确定性上限、人工确认直接衔接。

3.6.1 系统提示中的完成契约

Agent 系统提示把“任务完成”约束为可验证状态，而非自然语言自报。对于数据生产请求，Agent 必须先检查可用执行路线；正式成功需要取得正式发布物或明确的产物清单。若只能形成工作区 CSV，则必须标记为暂存并说明正式路线为何无法闭合。该契约直接针对三类常见幻觉——把工具预览当“数据集已完成”、把工作区文件当“正式发布”、对失败来源保持沉默并宣称“已完整检索”。

约束不止于提示词：运行时每回合注入由事件日志压缩而成、有长度上限的进度上下文，显式告知“尚无不可变发布物”“仍有工具在执行”“存在未解决失败”——把完成与否的真相锚定在数据产品的存在性上，而不是模型对自身行为的记忆（对抗样本与拦截记录见 ?? 节）。

3.6.2 路由预检与声明式工具 Schema

BioMed QAgent 系统向大模型暴露当前真实能力与相关参数。静态路线要求精确匹配注册表；动态路线只接受预检报告为可绑定的输入。工具的参数结构描述（Schema）严格约束字段类型、枚举、对象结构与必要参数，服务器端再做交叉验证。上下文工程的重点不是把所有代码塞进提示词，而是把模型作决策所需的最小权威信息放进上下文——当前任务与研究目标、可用工具及其严格输入结构、注册表返回的数据家族/表结构/提供者能力、来源搜索结果和失败回执、校验问题与人工确认选项及证据摘要、当前发布物或阻塞状态——把“模型知道什么”绑定到运行时实际能力，减少提示词与代码版本漂移。

3.6.3 技能体系与专用工具

专用能力以技能（Skill）形式组织，当前共 24 项，分三类。

其一，数据库类技能 14 项：PubMed、GEO、GDC、Xena、UniProt、PDB、PubChem、ChEMBL、ClinVar、GWAS Catalog、dbSNP、MGnify、openFDA、Reactome——每项封装对应入口的查询、分页与来源特有字段，Agent 不必为每个站点编写脚本；其中 13 个可在界面中作为内置数据库选择（GWAS Catalog 经 EBI 官方 API 供发现与动态路线使用，不进内置数据库选择器）。

其二，载体与取证技能：浏览器导航与页面取证、PDF 表格提取、图表视觉提取（Qwen-VL）、文献理解、网页视觉取证、搜索发现与本地缓存复用。

其三，流程技能：数据集构建引导、研究数据指引与分析。与前两类回答“会用什么工具”不同，流程技能回答的是“按什么方法把需求做成合格的数据产品”：数据集构建引导把“先做路线检查、再构造并校验数据集规格、最后只认正式发布物”的执行协议固化给 Agent；研究数据指引按主题提供数据源选择、清洗与可分析性判断的领域方法，并要求明确声明“查了哪些源、哪些相关源没有查”。这两类技能决定了 Agent 的开放式推理能否稳定地落在系统的信任边界内，是第??章各阶段获得合格输入、第??章各案例在无人工逐步指令下收敛的前提。需要说明的是：拥有数据库类技能不表示每个来源都有成熟的静态发布管线

——内置数据家族、可绑定的动态 provider 与仅作研究辅助的工具能力（VLM、PDF、浏览器、缓存等）是三层不同的能力，后两者不等同于固定数据家族。

技能是声明式的：扩展数据源只需描述来源与字段，不绕过网络策略、资产登记或注册解析器；工具层返回结构化结果与错误，Agent 据此调整查询或报告缺口，底层 I/O、权限与数据变换保持可审计。

技能还能从执行中生长：每次运行结束后，固化引擎把工具调用流还原为可复用脚本候选与技能文档候选——确定性步骤（查询、统计、本地执行）固化为脚本骨架，需网络或凭据的步骤只记录不固化——候选经人工评审后提升进技能库，形成“执行→分析→固化→复用”的闭环。技能库因此随使用积累，而不只随开发维护。

3.6.4 证据上下文与不确定性控制

模型不应仅看到最终值，还应看到该值的来源类别、定位信息、解析层级和置信度。对于非确定性抽取，系统以类别置信度、原因、模型身份和复核状态表示不确定性，并在 Core 中设置可信度上限。

字段映射和单位修正也采用相同原则：模型可以提出候选，但只有注册规则或绑定证据的人工决定可以改变正式数据。

4 Dataset Core: 确定性八阶段流水线

Dataset Core 是系统唯一的数据信任边界：八阶段固定流水线——采集→解析→规范化→兼容性检查→整合→派生→校验→发布（acquire → parse → normalize → compat → integrate → derive → validate → publish），每一步都有显式输入、操作收据、输出摘要与失败语义。Agent 的自主决策面见 ?? 节；决策进入 Core 后，执行路线固定、正式数据值由注册操作产出——动态数据家族（Family）允许 digest-bound 变换在隔离区产生候选字节，但须经闭世界准入、Validation、B3、ProductAssessment 与 Publisher 逐级把关后才成为正式值。动态家族扩展的是“能读什么”，不扩大“能写什么”。

详图展开 Core 内部：A 路线是已注册数据家族的固定操作骨架；B 路线是动态规格——变换方只交付候选字节，经隔离区与 Core 准入校验（重新计算摘要、闭世界检查）统一把关，且不能选择校验、评估或发布模块（创新点二的机制基础）。该准入的拦截实效见 ?? 节运行矩阵：表头与声明差一字段的变换被隔离区（quarantine）以 OUTPUT_HEADER_MISMATCH 拒绝（r5），占位符空壳 r4 曾是唯一穿透，随后以 PLACEHOLDER_CONTENT 内容筛查封堵。

八阶段运行在共同的可靠性基座上（?? 节）。流水线之外，系统以显式终态保证“运行完成≠正式发布”（拿不准就拒绝：Rejected / NO_DATA / Failed / Cancelled）。以下按八个阶段依次说明。

4.1 阶段1 acquire: 正式采集与来源资产登记

发现阶段拿到 URL 后，正式路线并不直接信任 Agent 工作区里的任意文件。Core 的采集提供者决定请求的 URL、方法、请求头、媒体类型和允许参数，经统一下载设施（URL/DNS 策略、大小与超时限制、重试、断点续传与内容缓存）执行网络访问，以降低服务端请求伪造（SSRF）、无限下载和重复获取等风险。文件写入任务专属的来源资产目录后，来源资产注册表流式计算 SHA-256 并生成内容身份，绑定任务与资产角色、文件字节数/媒体类型/SHA-256、来源 ID 与规范编号、提供者与采集实现的身份摘要，并在支持时记录快照身份或修订号等版本证据；目录逃逸、符号链接和跨任务资产复用一律拒绝。

因此，“来源资产”不是一个本地路径，而是任务、来源、内容与采集实现共同绑定的输入证据。

4.2 阶段2 parse: 异构数据解析

4.2.1 结构化与半结构化来源

正式静态路线使用已注册的解析器（Adapter）。解析器把来源特有的 CSV、JSON、XML、XLSX、SOFT、矩阵或 API 响应转换为数据批次（DataBatch），同时输出解析统计、被拒绝的记录和溯源定位信息。对于来源格式异常，解析器应失败或把问题写入审计记录，而不是让 Agent 猜测缺失字段。

表达数据的解析器需要识别样本列、实体标识、测量值和表达语义。例如 GEO 既可能提供 gene-level 结果，也可能只提供 probe-level 矩阵；系统不会在缺少可信注释时直接把探针当成基因。GDC 与 Xena 的输入形态不同，但都需要转换到目标表达表结构后才可合并。

注册式多表数据家族则将每个来源表映射到明确的表定义，并在后续组装阶段检查关系（多表示例见 ?? 节）。

4.2.2 PDF 表格

PDF 解析保留页面和位置证据。对于可提取文本的表格，可依据文本块位置聚类形成行列，并记录 page、bbox、caption 或降级警告。无框线表格、合并单元格、旋转页面和跨页表头仍是启发式解析的难点，应在 Gold 案例中单独标注复杂度并人工核对。

4.2.3 图表与视觉模型

图表工具采用多层降级：优先通过 Qwen-VL 理解页面图像或嵌入图像；失败时尝试 PDF 表格；再失败时提取标题（caption）作为有限信息。模型抽取结果必须携带模型名，点级结果包含置信度与置信度原因；其可信级受 4.7 的确定性上限约束，不会因模型自报 high 而自动成为正式真值。

规范侧已实现的是：结构化 chart-evidence 数据（含点级图表证据与来源绑定）经摘要绑定的证据资产进入生产 bioactivity_measurement 数据家族的图表四表；点级溯源与复核门在组装前“拿不准就拒绝”，未通过时写入结构化 chart_evidence_gate 检查并阻断发布，不会让任意工作区 CSV 直接获得正式发布权；人工修正（HIL correction）保留原始值并记录 human_correction 步骤。VLM/PDF/caption 抽取当前仍停在工作区 CSV，尚无生产转换/注册为 canonical chart-evidence 的通道，自然语言端到端案例仍待办。

轴与图例的正确性由确定性门禁而非模型自报约束：chart_series 表记录轴名、轴单位与刻度和图例

BioMed-QAgent Dataset Core

确定性数据处理流：从受控输入到不可变数据产品




图 4.1: Dataset Core 确定性数据流详图

文本，并须声明轴/图例校验状态 (clear / unclear / human_validated)；声明为 exact 的数值点一旦对应轴或图例语义 unclear 即直接判失败；系列允许省略点数据的唯一条件是轴或图例状态明确标为 unclear。该链路已有点级 Gold 闭环测试：采纳 (accepted) 与人工修正 (corrected) 两条路径均产出正式发布物并逐件重算 SHA-256，未复核或缺表则不产生任何发布物。

4.3 阶段3 normalize: 语义规范化与缺失、重复处理

解析后的来源记录仍不能直接拼接。规范化器 (Canonicalizer) 按目标表结构完成类型转换、规范字段命名、实体标识表达和必要的值标准化。其核心原则是：只有被目标表结构和规范化配置授权的变化才可以自动执行。

字段对齐处理来源列名到规范字段的映射、类型转换、缺失标记统一、实体 ID 与命名空间表达、单位与测量语义检查、probe-to-gene 等外部映射资产转换，并保留原始写法与规范值之间的血缘 (lineage)。缺失与重复按类型分层处理：必填字段缺失时拒绝或阻断，可选字段缺失保留为空并计入完整性统计；完全重复按确定性键去重；主键重复且值一致时合并血缘、保留多来源。每类处理都保留对应证据 (定位信息、来源集合等)，使后续可复核。

这些规则在案例中的形态：缺失分层在 gold8 表现为 4 行官方聚合确无词条的记录不产生行、不零填充并逐条列出，在 gold9 表现为可选证据列留空并计入完整性统计。

原始写法保留在 gold9 发布表中直接可见——HGNC 归一后的 hgnc_symbol 与来源原写法 orphanet_gene_symbol 并列成列，gene_records 另保留 alias_symbols 与 previous_symbols，归一不抹去历史身份。gold7 的变体-基因映射表 (127 行) 则整体来自补充材料这份逐研究注释资产，而非模型推测。

实体身份对齐同样采用确定性机制：化合物以 InChI Key 精确匹配建立交叉映射表 (如 ChEMBL↔PubChem，匹配方法 exact_inchi_key，匹配不上时显式标记为冲突而不强行合并)；基因符号归一有内置确定性映射表，也可使用注册的外部规范资产 (如 HGNC current，见 gold9)；probe→gene 依赖逐平台注释资产，未映射探针保留原命名空间、不静默丢弃。

4.4 阶段4 compat: 兼容性门

兼容性门是解析与规范化产物进入整合前的最后一道静态检查：核查各批次在数据家族、表结构、行粒度、实体层级、单位、语义和尺度上是否可合并，并按可计算的测量身份 (值语义、值尺度、单位) 与十二维语义 (模式、行粒度、物种、特征命名空间、测量类型、规范化状态、参考版本等) 生成确定性的合并域键——任何一维不一致，都不能进入同一合并域。

未知单位、未知值语义或不受支持的数值尺度不会被自动修正；单位不一致时，只在有注册转换公式时换算，公式只接受四种线性安全形式 (value、value±o、value×f(±o) 与 value/d)；没有注册规则时阻断，或经人工确认请求研究者选择合法的修正。

两个案例化说明：坐标基准转换不属于任何线性安全形式，系统不做 GRCh37→GRCh38 的自动换算，而是双列并存、交由外部权威核验——gold7 的 position_grch38 (dbSNP 核验) 与补充材料列 position_grch38_supp 并列，两个来源不一致时直接可见；gold9 中 ClinGen 的序数分类与 ClinVar 的记录计数测量身份不同，各自成列，不进入同一合并域。

4.5 阶段5 integrate: 多源整合与冲突审计

对同一规范表结构的批次，整合器按注册的合并策略合并，并在最终来源权威行 (source-of-record) 上重新汇总血缘和置信度。合并时的冲突按注册策略处理：主键重复且值冲突时保留来源权威行并写冲突审计，必要时阻断；实体身份冲突不强制合并而保留交叉映射表；统计异常作为警告或人工核查信号，不默认自动改值。

整合层优先做“可复核的记录”，而不是“替研究者定案”。gold7 是实测样本：locus 表以 rsID 为合并键，GWAS Catalog 关联与补充材料 75 位点表在主键上重叠、值一致时合并血缘并保留双来源标记 (in_supp_75_loci)；同一坐标的两个来源值以双列并排保留而非静默取舍——这些字段对齐与冲突记录由规范化、兼容性阶段与整合器的确定性规则共同完成，冲突审计随产物交付，无法自动裁决时才发起人工确认 (?? 节)。

真正需要“二选一”的少数同键冲突，表达整合采用先到先得 (first source wins) 作为可复现的终局裁决；裁真仍显式保留给研究者与人工确认 (边界定性见 ?? 节边界 5)。

4.6 阶段6 derive: 多表组装

对于需要多实体关系的数据，数据家族的组装阶段生成多表候选，并检查主键、外键、基数和表角色。

单表与多表是规格层可选形态：需求本身是单一粒度观察时（如 gold8 的 FAERS 计数）交付单表；需求横跨多个实体层级时（如 gold7 的研究-位点-映射、gold9 的基因-疾病-证据）才拆分多表——以生物活性数据为例，拆分为测量值表（activities）、实验条件表（assays）、化合物与靶点规范身份表（compounds/targets）、来源表与化合物交叉映射表（compound crosswalks）等，避免把不同粒度的观测压进重复严重的宽表。

多表发布清单记录表、关系、溯源引用和置信度引用，下游按显式关系而非列名猜测连接键（join key）；对习惯合并宽表的下游统计流程，研究者可在目标表结构中把交付声明为单表粒度（如 gold8）。

4.7 阶段7 validate: Validation、Confidence 与 ProductAssessment

校验配置（Validation Profile）对候选结果执行发布前检查，覆盖：表结构与字段类型、必填字段完整性与允许缺失率、主键唯一性与外键基数、实体标识命名空间与原始写法保留（token preservation）、单位/数值尺度/允许语义、溯源与来源定位覆盖、置信度记录与最终行对齐、产物摘要闭合，以及可复现所需的输入与实现身份。多表产品评估（ProductAssessment）从结构、关系、标识、溯源、置信度与可复现性六个维度评价产品。无阻断项时判定为“可发布”（publishable）；只存在可复现性阻断项时至多为“已验证”（validated）；存在语义阻断项时为“不完整”（incomplete）。这使得“CSV 能打开”与“数据产品语义上闭合”不再是同一件事。

置信度按证据类型受到上限约束。确定性、受版本约束的解析可以获得较高可信等级；VLM、LLM、OCR 和网页抽取等非确定性来源最高封顶为 medium，并可按记录进入人工审核。系统关注的是“该记录由何种证据和处理产生”，而不是让模型自由输出一个看似精确的概率。

验证结论还与显式终态绑定：Rejected、NO_DATA、Failed、Cancelled 四类终态相互独立且“拿不准就拒绝”——空主数据、兼容性失败或验证失败的结果一律不可发布，“运行完成”不等于“发布物生成”（对抗样本及其拦截记录见 ?? 节）。

4.8 阶段8 publish: 不可变发布与消费时重验

发布者把通过质量门的候选复制到独立目录，生成发布清单（Manifest），并为每个文件记录相对路径、媒体类型、字节数和 SHA-256。典型正式产物包括主数据集与辅助数据集 CSV、表结构、溯源、审计/校验报告，以及发布清单与发布回执。

发布采用临时目录与原子切换；发布前检查执行锁与代次围栏（表 ??），防止超时或取消后的旧操作晚到覆盖新结果。产品 API 在读取时重新验证发布清单与文件摘要；若文件被修改或损坏，返回错误而不是继续展示。这里的“不可变”指正常 API 下只追加发布、不覆盖旧版本；读取端按清单重算摘要可检出意外或不完整篡改，但不提供同一 OS 账户完全重写文件系统时的密码学防篡改。

4.9 Durable HIL 与可恢复执行

人工确认（HIL）不是系统的第一反应，而是在确定性规则穷尽后的兜底环节：遇到模糊的字段映射、未知单位、低置信度图表点等，Core 先尝试注册的确定性规则与候选推理，只有无法安全定案时才创建结构化请求——例如单位换算先查注册公式表，命中即自动应用、不进入人工确认，仅当无规则可依时才暂停；图表审核只针对低置信度记录发起。请求携带逐项候选值（proposed_value）与置信度（confidence_level）、相关记录、证据摘要和任务/运行/需求身份，前端以“在候选与证据概要上选择”为主、自由修正为辅（approve / reject / correct）；响应只有在证据摘要和任务身份匹配时才可恢复原操作。

典型场景包括字段映射存在多个候选、未知单位或测量语义、probe-to-gene 映射歧义、低置信度图表点确认，以及冲突记录需指定保留策略等。

从审批对象看，人工确认覆盖三级：工具许可与凭据授权（approve/reject）、数据审核（字段映射、单位、图表与网页证据）、发布验收。其中发布验收针对需要验收的高风险产品（动态发布、图表证据、浏览器证据接受）不可绕过——只有人工 accept 后系统才执行发布；普通静态数据发布不统一要求 publication-acceptance HIL，这与“Core 独占发布权”互为表里。

审批档位按对象配置：每类审批范围可设 human_review（人工审批）、llm_pre_review（LLM 初审，仅不通过项上报人工）或 auto_approve（显式自动通过）；初审不通过或模型调用失败一律回退人工（fail-safe），发布边界范围强制人工、配置其他档位会被直接拒绝。低风险确认可配置自动放行，需要发布验收的高风险场景（动态发布、图表证据、浏览器证据接受）始终人工。

请求和决策均落盘，进程重启后可以确定性恢复：系统持久化审批挂起时的原始工具调用，恢复时以原调用重放并由执行器从检查点续跑，零 LLM 参与；主机重启后无法确定性续跑的发布验收直接判整次运行失败，悬空的权限请求一律清算为拒绝。对于数据更正，系统重新执行受影响阶段并发布新版本，通过

supersedes 关系保留旧版本历史。

需要澄清的是：判失败的是无法确定性续跑的单个运行，其中已完成且摘要一致的阶段仍经检查点复用、不会整体重跑（gold9 中断后续测一次通过即为实例，见 ?? 节），因此基础设施故障不会丢失已完成的工作。

4.10 可靠性基座

八个阶段运行在共同的可靠性基座上。表 ?? 逐项给出机制定义与运行日志中的实测记录：

表 4.1：可靠性基座：机制与实测记录

机制	一句定义	实测记录
执行锁	同一任务同一需求的发布互斥； 目录原子锁，单机多进程有效	开发期主机重启曾打断进行中的运行（gold7 两轮），锁内旧执行不再写入
代次围栏	发布前复核执行租约，超时或已取消的旧执行不得晚到覆盖新结果	gold9 前两轮因主机崩溃与资源耗尽中断，新执行安全接管后续测通过
检查点与重放	已完成且输出摘要一致的操作按重放身份复用	gold9 中断后续测一次通过，未重跑全链路
超时与取消	每个操作有界，取消即时生效	gold9 会话取消路径的无界等待缺陷被定位并以强制取消修复
事件溯源	全部操作追加事件日志，状态可由日志重建	qwen3.7-plus 三轮谎报“整合完成”被事件流的终态分类标为未完成（?? 节）
Durable HIL	审批请求与决策落盘；恢复以原调用重放、零 LLM 参与	机制与三档审批见 ?? 节
内容摘要与重验	逐件 SHA-256；读取端每次读取重算，不匹配即拒绝展示	三案例全部产物经监督程序逐件重验一致（?? 节）

5 实验与案例

本项目整理了 10 份参考输入输出样例，覆盖表达组学、变异、靶点证据、结构、生物活性、论文图表提取、GWAS、药物安全、罕见病关联与微生物组十类场景。完整问题列表如下：

表 5.1: Gold 案例总览（案例 1–10）

案例 ID	研究主题	主要来源	主要难点
1	乳腺癌肿瘤 vs 正常组织 GEO 转录组表达整合	NCBI GEO / E-utilities + GPL 平台注释	探针→基因映射、缺失、冲突、单位/尺度
2	LUAD EGFR 突变表达的基因/探针双粒度整合	GEO + 临床与 EGFR 突变注释	probe→gene 双粒度、临床表型字段对齐
3	EGFR NSCLC 靶点多源证据整合	UniProt、NCBI Gene、ClinVar、RCSB PDB、PubChem、ChEMBL、ClinicalTrials.gov、COSMIC	跨数据库 identity 冲突与 crosswalk
4	SARS-CoV-2 Spike-ACE2 结构、序列与变异证据	NCBI、UniProt、RCSB PDB、PubMed、Europe PMC	派生行不得冒充来源行、结构版本与 interface
5	EGFR 抑制剂 ChEMBL 活性与 PubChem 结构整合	ChEMBL、PubChem	compound crosswalk、单位、identity 冲突
6	EGFR 突变体抑制实验与论文图表提取	PubMed / PMC / Europe PMC（PDB 仅校验）	低置信度图表点阻断至人工、轴/图例校验、图表提取
7	阿尔茨海默病 GWAS 风险位点多源整合	GWAS Catalog + Bellenguez 2022 补充材料 + dbSNP GRCh38	补充材料 75 风险位点解析、坐标版本
8	药物性肝损伤（DILI）风险药物证据整合	FDA DILIRank 2.0、LiverTox、openFDA FAERS	外部来源失效（DILIRank 404）、来源切换策略
9	原发性免疫缺陷基因-疾病-表型整合	Orphadata、HGNC、ClinVar、ClinGen	疾病归一、跨源证据分级
10	肠道微生物组-疾病关联整合（T2D/IBD/CRC）	MGnify、GMRRepo、病例对照论文、NCBI Taxonomy	动态路线闭合、分类学术语归一

十案例中，gold7–gold9 在同一冻结代码版本、单一主机、同一评测协议下完成并重点展开，分别代表三类典型难点：动态多表拓扑闭环（gold7）、外部来源失效下的部分维度发布与结构化阻断（gold8）、多源多表整合与跨源证据（gold9）；gold10（肠道微生物组）在独立冻结代码版本下亦达成四表正式发布。

gold1–6 为参考样例，覆盖表达/变异/靶点/结构/活性/图表六类场景，未纳入本轮冻结评测协议。各正式执行案例的声明宇宙与结局总览见表 ??。

需要说明工程投入与案例规模的关系：上述机制是赛题赛道能力（来源发现与覆盖、异构解析、清洗整合、图表提取与全链路溯源）的实现本体，属于一次性基础设施投入——gold7–10 四个正式案例在冻结代码与同一评测协议下复用整套机制，新增普通场景只需登记来源与配置，而非重建流水线。

因此，仅以单个案例的产出行数衡量投入，会忽略两点关键价值：可复现性（同一输入必然产出相同结果）与审计性（每行可溯源、每步可重验、发现问题可定位修正），后者正是“可信科学数据编译器”区别于一次性手工整理的所在。

表 5.2: 正式执行案例的声明宇宙与结局总览

案例	声明宇宙	对宇宙覆盖	对参考集	模型	终态
gold7	Bellenguez 2022 补充材料 + GWAS Catalog GCST90027 158, dbSNP 核验坐标	Catalog 89 条关联与补充材料 75 位点表全部解析, 落表 1/88/127 行	覆盖 3,109 参考 locus 行的 2.8% (单研究绑定, 边界 4)	deepseek-v4-flash	正式发布
gold8	9 个已验证药物× 8 肝毒性 PT (可达维度)	68/72 行落表; 4 行官方确无词条、未零填充	请求约 50 药中式化 9 药 (DILIrank/LiverTox 不可达, 边界 2)	deepseek-v4-flash; qwen3.8-27B 亦有同类发布	可达维度正式发布 + 不可达维度结构化阻断
gold9	Orphadata × HGNC 四表, ClinVar/ClinGen 证据列	四表全交付 (213/269/241/241 行), 结构校验 67/67	四源中两源数值落表; 证据列留空 (边界 3)	deepseek-v4-flash	正式发布
gold10	IBD 表型: MGnify、GMRepo、文献补充差异表、NCBI Taxonomy	四表全交付 (1/30/19/598 行), 校验 63/63, 溯源覆盖 1.0	参考 3 表型/ 1,887 差异行的 IBD 子集; T2D/ CRC 差异表源均不可达、显式标注	deepseek-v4-flash	正式发布

“声明宇宙”指该次执行实际声明的目标范围，由需求原文与 Agent 的路线决策共同确定；对参考集的差距及其原因统一见 ?? 节。

5.1 案例评测协议与总览

为保证结果可复核，重点案例遵循同一评测协议：Agent 的输入只有案例需求原文（数百字节的研究需求描述，不含任何参考答案或人工整理数据），代码冻结在单一版本；由独立的外部监督程序驱动任务，把事件流持久化落盘，对发布产物逐件重新下载并重算字节与 SHA-256，最终给出三类终态判定（成功发布 / 未发布阻塞 / 失败或取消）。

评测模型为 DeepSeek-V4-Flash（上下文窗口 1,000,000、最大输出 32,768、温度 0.2）——选择一个非 Qwen 的国产模型是为了验证系统的模型无关性。Qwen 侧能力并非空白：此前 gold8 已在同链路上取得 Qwen3.8-27B 的同类正式发布，Qwen-VL 承担图表理解链路（?? 节），全模型谱系的行为分层见 ?? 节。另需说明时间线：重点案例的代码冻结早于占位符内容筛查的落地，但三案例产物均在筛查落地后经监督程序逐件 SHA-256 重验，与参考集的结构对照见 ?? 节。

表 5.3: Gold7–9 正式发布与校验结果

案例	研究主题	交付物	校验	上下文峰值
gold7	阿尔茨海默 GWAS 风险位点多源整合	三表 (study / locus / variant_gene_mapping) + 表结构 + 溯源 + 评估	逐件 SHA-256 通过	766,326 / 1M (76.6%)
gold8	DILI 风险药物证据整合	faers_reaction_counts 主表 + 表结构 + 溯源 + 评估 (4 件)	逐件 SHA-256 通过	380,287 / 1M (38.0%)
gold9	原发性免疫缺陷基因-疾病-表型整合	四表 (gene / disease / gene_disease / crosswalk) + 表结构 + 溯源 + 评估 (7 件)	逐件 SHA-256 通过; 结构校验 67/67	750,739 / 1M (75.1%)

三例全程未出现命令直连绕路或网络绕过，也没有发生权限暂停；上下文峰值均远低于窗口，未触发压

缩。全部事件流、发布清单与重验记录（需求原文、中间产物、溯源记录与逐轮运行日志）均随项目资料完整保留，可按案例逐项核查复现。

5.2 案例 gold7：阿尔茨海默 GWAS 风险位点整合（动态 Family 全链闭环）

输入（需求摘要）：以 Bellenguez 2022（PMID 35379992）等来源整合 AD GWAS 风险位点，输出研究、位点、变异-基因映射三张表，要求补充材料 75 位点表解析与 GRCh38 坐标核验。过程要点：Agent 首步调用路线检查（inspect_dataset.execution_routes），确认静态注册表无任何数据家族能表达该三表拓扑后选择动态路线；随后经治理工具完成采集——GWAS Catalog REST 返回 GCST90027158 的 89 条全基因组显著关联；Europe PMC 官方补充通道取得 27,656,649 字节归档（SHA-256 逐字节登记后作为任务资产），Core 提取器将 XLSX 成员逐工作表转为溯源绑定的 UTF-8 CSV 资产；dbSNP 工具核验 GRCh38 坐标。

正式发布前，动态预检拒绝了 11 次规格提交（角色映射、输入闭包、外键策略、字段形状等），每次均给出可操作的错误信息；Agent 修正后发布 v1，又自行发现 v1 的 GWAS 统计列未填充与解析缺陷，发布修正版 v2 并以替代关系保留 v1 历史——这一“自检-修正-换版”行为是完成契约与显式终态约束下的 Agent 自检闭环样本（人工反馈闭环机制见 ?? 节）。输出结构（v2，study.csv 1 行、locus.csv 88 行、variant_gene_mapping.csv 127 行）：locus.csv 24 列，含双坐标基准对照（position_grch38 与补充材料 position_grch38_supp）、分层统计（stage1/stage2/stage12 的 OR 与 p 值）、异质性（i2/phet）与来源标记（in_supp_75_loci、dbSNP_variant_type）。真实样例行：

表 5.4: Gold7 locus 真实样例行（v2）

字段	值
variant_rsid / risk_allele	rs141749679 / C
position_grch38 / _supp	109345810 / 109345810
p_value / odds_ratio / CI	8e-9 / 1.38 / [1.24-1.54]
nearest_gene / known_locus	SORT1 / New
stage1_or · stage2_or	1.37 (1.19-1.57) · 1.41 (1.17-1.7)
i2 / phet / in_supp_75_loci	0 / 0.9019 / yes

来源清单：GWAS Catalog 关联记录（GCST90027158）、Bellenguez 2022 补充材料（Europe PMC 官方归档，字节级摘要入链）、dbSNP RefSNP 记录。发布范围窄于参考全集——正式绑定的是单研究，映射基因全部来自补充材料——但每一行均可溯源、可重验；该范围取舍与其余边界见 ?? 节。

5.3 案例 gold8：DILI 风险药物证据整合（来源失效下的正确终态）

输入（需求摘要）：针对 DILIrank 2.0 vMost 药物整合三类证据——DILIrank 标签注释、LiverTox 专论、openFDA FAERS 肝毒性 PT 报告计数，约 50 种代表药、四表交付。

关键难点与行为：DILIrank 2.0 官方文件（fda.gov/media/113052/download）持续 404，LiverTox 无药物级结构化导出。系统的处理展示了赛题“自动识别缺失数据……完成修正或寻求人类建议”加分项的完整链路：第一轮运行在发现阶段确认官方来源不可达后未编造任何行，以工作区暂存 + 结构化阻断收尾，明确请求“提供官方文件或注册 Core 资产”；第二轮定向续跑把可达维度（FAERS 计数）正式化——9 个已验证药物各经一条 openfda.files.v1 Core 采集绑定重新获取（发现阶段的查询输出不被当作正式载体），以动态数据家族发布。

这一“核实不可达→显式阻断→定向续跑→正式化可达维度”的降级链，正是提案加分项“自动识别缺失数据并完成修正或寻求人类建议”在数据链路上的落地；不可达维度的替代源自动发现为已识别的改进方向（?? 节边界 2）。

输出结构：faers_reaction_counts.csv 68 行×5 列（drug_name, reaction_pt, report_count, retrieval_method, source_url）。请求的 9 药×8 肝毒性 PT = 72 行中，4 行因官方聚合响应确无该 PT 词条而未零填充，逐条列出（如 azathioprine-HEPATOCELLULAR INJURY）；其余 68 行与发现阶段 openFDA 计数逐条一致（如 acetaminophen ACUTE HEPATIC FAILURE = 3297）。

校验 16/16 通过（0 坏行、0 重复主键）、溯源 9/9 载体满足、product_status=publishable。每行 source_url 直接给出可复核的官方 API 查询串；report_count 的语义为 MedDRA PT 报告次数（非去重患者、非因果证据），已在终答与溯源中注明。不可达的 DILIrank vMost 名册与 LiverTox 维度不进入正式

发布，仅保留为明确标注暂存的工作区文件——“部分维度正式发布 + 不可达维度结构化阻断”是该上游条件下的完成形态，也是 ?? 节显式终态语义的一次实战兑现。需要说明的是，这里的阻断并非“不做替代”：第三方镜像或转载无法进入字节级证据链，系统因此不会自动改换来源，而是结构化地请求研究者提供官方文件。

可靠的替代源自动发现（从文献补充或其他官方通道补 DILI 证据）已列为规划中的合规扩展。其余边界见 ?? 节。

5.4 案例 gold9：原发性免疫缺陷基因-疾病整合（多源四表与跨源证据）

输入（需求摘要）：从 Orphadata 筛选免疫缺陷相关罕见病及基因关联，经 HGNC 归一为现行符号，整合 ClinVar 致病性变异计数与 ClinGen 有效性分类，输出基因、疾病、基因-疾病关联、跨源证据四表，以 hgnc_symbol/orphacode 关联，ClinGen Refuted/Disputed 冲突单独标记。

过程要点：Orphadata 两个大型 XML（en_product1 54,026,799 字节、en_product6 22,612,034 字节）经任务内容缓存命中（先前由同一官方端点获取并逐字节验证，摘要一致），零网络重取；HGNC、ClinVar、ClinGen 为本轮运行真实网络采集。

前两轮运行因基础设施缺陷（浏览器渲染超大文件导致资源耗尽、会话取消路径无界等待）中断——两个缺陷均被定位并修复（渲染资源闸门、强制取消），续测一次通过，本身即 ?? 节与 ?? 节“可恢复性”目标的工程实证。

输出结构（四表）：gene_records.csv 213 行（HGNC 现行身份，含别名与历史符号）、disease_records.csv 269 行、gene_disease_records.csv 241 行（主表，保留 orphanet_gene_symbol 原写法）、gene_evidence_crosswalk.csv 241 行（ClinGen 有效性分类 + ClinVar 计数 + 冲突标记）。

关联样例（gene_disease_records）：567,TBX1,TBX1,"T-boxtranscriptionfactor1","Disease-causinggermlinemutation(s)in;Roleinthe phenotypeof",Orphaneten_product6。结构校验 67/67 通过（候选引用闭合、逐表的表结构契约、主键唯一、外键关系、溯源覆盖等），product_status=publishable。

来源清单（五个正式载体，溯源逐条登记回执、请求身份摘要与官方端点快照）：en_product1（54,026,799 B，df8d562a128）、en_product6（22,612,034 B，f1c039f7128）、HGNC current（16,948,051 B）、ClinVar gene-esearch（460 B）、ClinGen current（1,119,208 B）。

本例闭合的是 Orphadata×HGNC 两源四表与完整的发布、溯源、验证链；crosswalk 的 ClinVar/ClinGen 数值列留空（两个载体已获取绑定，但值未落入交叉表），该偏差的机理与处置见 ?? 节边界 3。

5.5 多模型对抗性验证与能力分层

重点案例由单一模型完成。为回答“换用 Qwen 系模型（含更低档位）时正式发布全链路是否可用、失败是否落在正确拦截层”两个问题，我们在 gold7 同一需求上开展了一轮 10+ 次的多模型直问验证：以真实研究问题直接建任务，用户消息只含数百字节的研究需求原文，机制与约束全部属于系统提示词与工具描述，由监督程序逐轮记录结局、首要失败模式与拦截层（表 ??）。

表 5.5: gold7 多模型直问验证运行矩阵（按时间序，2026-08-29）

轮次	模型	结局	首要失败模式	拦截层	随后落地的修复
r1	qwen3.7-flash	blocked	bootstrap 残留指令劫持（尾段只回 READY）	—（提示词层）	bootstrap 废除→supervisor --adopt
r2	qwen3.7-flash	blocked	prepare 契约 25 次不收敛（含 2 次自造 digest）	preflight 逐字节校验	契约细节转正进工具描述/系统提示词
r3	qwen3.7-flash	拦停	submit 回显失真×12 后请求读取盘外路径	supervisor 白名单	receipt-only submit
r4	qwen3.7-flash	发布成功但为占位符空壳	占位行（UNKNOWN/placeholder）	未拦住→立案修复	PLACEHOLDER_CONTENT 准入筛查

轮次	模型	结局	首要失败模式	拦截层	随后落地的修复
r5	qwen3.8-flash	blocked	transform 输出表头与声明差一字段	quarantine OUTPUT_HEADER_MISMATCH	沙箱方言进系统提示词
r6	qwen3.8-flash	blocked	三类拒绝循环不收敛（35 prepare / 18 submit）	preflight + quarantine	prepare 键差点名报错
隔离1	deepseek-v4-flash	blocked	首次 prepare 墙前放弃，转工作区	supervisor（诚实分类）	提出温度假设（0.2 vs 0.7）
隔离2	deepseek-v4-flash	拦停	直接转 python 解 zip	supervisor	证伪温度杠杆→ 确认数据可见性缺口
直问1	qwen3.7-flash	拦停	盲写 transform 触沙箱拒绝后转 python	supervisor	沙箱方言进系统提示词
直问2	qwen3.7-flash	blocked	零正式尝试即交“临时结果 + 假阻塞”	supervisor 诚实分类	end-of-run 发布闸门
直问3	qwen3.7-flash	拦停	发布评估拒绝后转 python	supervisor	receipt-only 绑定修复 + 拒绝携带 check 详情

矩阵给出两个结论。其一，护栏纵深有效：十一轮中每一次错误都落在对应拦截层——预检逐字段校验拦伪造摘要、隔离区（quarantine）拦表头与占位符、监督程序（supervisor）拦越权读盘与命令执行、终态分类拦伪阻塞——没有任何编造行进入过受验发布；唯一穿透（r4 占位符空壳发布）当日立案，并以 PLACEHOLDER_CONTENT 准入筛查修复。每个未拦住的失败模式都转化为一条产品修复并复验，绝大多数已落地主线。

其二，模型能力分层清晰（表 ??）：多数“模型失败”实为产品可观测性与工效缺口——数据不可见、错误不点名、逃生门太顺手——已按此顺序修复。

表 5.6: 模型能力分层

模型	观测表现	定位
DeepSeek-V4-Flash	从零启动首跑即自行收敛；gold7/8/9/10 四案例正式发布（??-?? 节、表 ??）	评测主力，验证模型无关性
qwen3.8-27B	gold8 正式发布	Qwen 中档可闭环
Qwen-VL	图表理解链路生产组件（?? 节）	赛题图形侧的 Qwen 支点
qwen flash 档（3.7 / 3.8）	十一轮直问零正式发布；六种失败模式，最佳轮次推进至发布评估最后一级（直问3）	能力边界如实分层
qwen3.7-plus	gold7 早期多轮失败：不走正式路线、三轮谎报“整合完成”（build.result 为 null）、Catalog 端点 404	高档位正式发布尚未取得

5.6 与参考集的对照

Gold 案例配有参考输入输出，正式发布的范围由 Agent 在证据约束下实际闭合的部分决定，可能窄于参考全集。表 ?? 冻结三案例的参考集规模与正式发布规模对照。口径说明：参考行数取自各轮运行的参考结构记录，发布行数取自发布清单；行级覆盖率、字段命中率与数值一致性的脚本化对照尚未产出（?? 节边界 7）。

表 5.7: 三案例与参考集的规模对照

案例	参考集规模	正式发布规模	差距定性
gold7	241 study / 3,109 locus / 2,216 mapping 行	1 study / 88 locus / 127 mapping 行	正式绑定单研究（GCST90027158），映射基因全部来自补充材料；多研究扩展见 ?? 节边界 4
gold8	约 50 种请求药物× 8 肝毒性 PT（72 行）	9 药、68 行落表（4 行官方聚合确无该 PT，未零填充）	DILIrank 名册与 LiverTox 维度不可达，结构化阻断而非静默缺失
gold9	需求指定的四源整合（Orphadata、HGNC、ClinVar、ClinGen）	两源四表 213 / 269 / 241 / 241 行	ClinVar/ClinGen 数值列未落表（载体已绑定，?? 节边界 3）

两点读法。其一，发布窄于参考的每一处都是显式披露的范围取舍或上游失效结果：未被覆盖的部分要么以结构化阻断交付（gold8 不可达维度），要么作为边界随产物披露（gold7 单研究绑定、gold9 数值列空），已发布行全部可溯源并经逐件 SHA-256 重验；结合表 ?? 的声明宇宙口径，gold7 对其声明宇宙（GCST90027158 的 89 条关联与 75 位点补充表）为全量解析。

其二，gold9 暴露的是校验维度的差距：四表行数与参考结构一致，但可选列填充率不在结构校验范围内（?? 节边界 3）。

5.7 可调用测试 API 与可交互前端

系统以 HTTP API 与 Web 前端同时暴露全部能力：API 覆盖健康自检、任务创建与名单、run 续跑/取消/恢复、权限裁决（approve/deny，绑定证据摘要）、发布物与逐 artifact 下载（消费时重验 SHA-256）及事件流实时订阅；前端（React 19 + Vite + Tailwind）提供任务列表与创建、run 事件时间线、发布物查看、人工确认结构化问卷（approve/reject/correct，覆盖字段映射/单位/发布确认等场景）与模型设置页。开发入口 `pnpmdev`（Host 8000 + 前端中间件），生产入口 `pnpmstart`；案例的完整复现命令已在仓库 `docs/plans/` 与 `docs/gold-formal-rerun.md` 固化。

5.8 结构化输出样例与字段说明

以 gold9 跨源证据交叉表为例（真实发布行）：

```
hgnc_symbol,orphacode,clingen_classification,clingen_classification_date,clingen_disease_label,  
  ↪ clinvar_count,clinvar_query,conflict_flag,conflict_detail  
TBX1,567,,,,,NONE,
```

字段语义：`clingen_classification` 为 ClinGen 基因-疾病有效性分类（Definite/Strong/Limited; Refuted/Disputed 出现时触发冲突逻辑）；`clinvar_count` 为 ClinVar 致病记录计数，`clinvar_query` 保留实际查询串供复核；`conflict_flag` 取 NONE 或 `CONFLICT_CLINGEN_REFUTED_OR_DISPUTED_WITH_ORPHANET_ASSOCIATION`。空值即“来源未覆盖该单元格”，系统不以零或推断填充（gold9 中两列整体为空的边界说明见 ?? 节）。

输入侧同理：一个来源凭据不是“一个下载文件”，而是任务、来源、字节摘要与采集实现身份共同绑定的证据对象（来源凭据逐条登记）；发布清单对每个文件登记路径、字节数与 SHA-256，读取端每次读取都重算摘要，文件被改动即拒绝展示。

5.9 案例结论对照赛题评价标准

表 5.8: 案例对照赛题评价标准

评价维度	案例证据	尚存边界（详见 ?? 节）
数据查找完备性	路线检查 + 多库治理采集（GWAS Catalog/ Europe PMC/dbSNP、openFDA、Orphadata/ HGNC/ClinVar/ClinGen、MGnify/GMRepo）； 不可达来源显式阻断而非静默缺失	覆盖证据尚未随产物交付（边界 6）
来源可追溯性	全部正式行携带 source_url/locator；输入载体 字节级摘要入链；发布产物消费时重验	gold9 跨源数值列未落表
清洗整合可靠性	动态预检 11 次结构化拒绝迭代；v1→v2 自检 换版；68/72 行真实缺失逐条列出；四表主外键 闭合 67/67	先到先得（first source wins）非 裁真（??）
输出格式可用性	各案例均交付 CSV+Schema+Provenance+ Validation+Manifest 的不可变发布，逐件 SHA-256 经第三方监督重验	端到端图表案例尚未交付；点级 发布闭环已有测试覆盖（边界 1）

5.10 能力边界与处置

需要先说明边界披露的性质：它是能力诚实性设计（?? 节目标六）的落地形态，与“能力未实现”不同——多数边界是范围取舍或上游失效下的正确处置，每条都有对应的处置路径。本节统一收拢各案例的适用边界——范围取舍、上游失效下的处置与已识别偏差——并给出处置方式：

表 5.9: 案例能力边界与处置

#	边界	性质	处置
1	图表抽取链路已有点级正式发布闭环测试（?? 节：采纳与人工修正双路径产出发布物、逐件 SHA-256 重验、未复核或缺表即拒绝），但尚无含图表场景的端到端案例	案例覆盖（点级已闭合）	点级闭环已由测试锁定；端到端图表案例对齐加分项“自动识别图表坐标轴或图例解析错误”
2	gold8 DILIrank vMost 名册与 LiverTox 维度保持暂存阻断；FAERS 计数语义为 MedDRA PT 报告次数（非去重患者、非因果证据）	上游失效下的正确终态	官方文件恢复后即可闭合；替代源自动发现为已识别改进方向
3	gold9 crosswalk 的 ClinVar/ClinGen 数值列未落表（ClinVar 载体仅绑定单基因 BTK）；结构校验不含可选列填充率	已识别偏差，记入案例档案	可经 ?? 节反馈-修正-换版闭环落表，无需重跑全链路；填充率检查列入校验清单改进
4	gold7 正式绑定单研究（GCST90027158）；映射基因全部来自补充材料（GWAS Catalog authorReportedGenes 为空）；样本量元数据未正式绑定	范围取舍	已随发布披露；可扩展多研究绑定
5	同键冲突的终局裁决 first source wins：保证复现但不构成科学裁真；双列并排与冲突审计已保留全部候选（??）	设计取舍	冲突审计随产物交付，裁真保留给研究者与人工确认
6	全局 QueryPlan / SourceCoverage 证据未随产物交付（??）	规划能力	覆盖只在预定义源集合内计算，不宣称“全网查全”；产品化设计见 ?? 节
7	与参考集的对照为手工冻结数字（??）；行级覆盖率、字段命中率与数值一致性尚未脚本化	量化评测缺口	冻结参考集并将对照脚本化，列入后续评估改进

上述边界或作为显式元数据随正式产物交付，或被结构化阻断在正式发布之外——这是 ?? 节“能力诚实性”目标的落地形态。

6 总结与讨论

6.1 相较基线的收益与消耗

分别以“纯人工整理”和“纯 Agent 问答”为基线，表 ?? 归纳本系统的收益与新增消耗。

表 6.1: 相较两条基线的收益与消耗

基线	本系统的收益	新增消耗
纯人工整理	消除多库重复查询与下载、手工复制对列与统一缺失值、逐条查证来源与版本、人工检查主外键/重复/冲突、中断与错误后的重做，以及为下游补写表结构与来源说明	token 与模型调用费用（Agent 推理、Qwen-VL 图表抽取）、来源文件/检查点/审计/发布物的存储、SHA-256 与验证的计算开销、数据 API 访问费用、模糊映射与冲突的人工审核、新数据源接入的一次性适配
纯 Agent 问答	把对话输出升级为可复用、可核验的数据产品：确定性可复现、来源与版本证据、发布前质量门与冲突审计、可恢复可修正，而纯 Agent 的自由改写难以稳定复现、中断后往往整体重来	高于“一次问答”的模型与验证开销、产物持久化与维护、流程中的人工介入点（纯 Agent “先回答后纠错”完全自助但没有质量保证）、数据家族表结构/解析器/校验配置的一次性投入

项目的价值不应表述为“消除人工”，而应表述为：把人工从重复搬运转向对科学语义、不确定性和冲突的高价值核对，并使这些核对结果可持续复用。

6.2 对科研数据适用性的实际意义

对研究者而言，正式发布物比聊天答案更接近可纳入科研流程的数据对象：它被脚本读取，有明确表结构，包含来源与质量说明，可以在发现错误时定位并修正。对团队协作而言，发布清单和 supersedes 关系降低了“每个人手里有一份不同 CSV”的风险。

对后续知识图谱、统计分析或证据推理而言，多表关系和溯源提供了比宽表复制更稳定的输入。能力边界随正式产物显式交付（?? 节），是上述意义成立的前提。

6.3 结论

BioMed-QAgent 针对赛题“从科学问题到可用数据”建立了一条从自然语言需求、来源发现、正式采集、异构解析、字段规范化、多源整合、质量反馈到不可变发布的闭环。

其关键在于把模型放在适合开放式推理的位置——Agent 作为数据产品的设计者，自主主导检索策略、来源评估、多表规格设计与自检换版（?? 节）——并把正式数据改变交给可验证的 Dataset Core。

系统把“任务完成”定义为可重验的数据产品：每条正式数据都能说明它从哪里来、经过什么处理、质量如何、何处不确定，收到反馈后能定位修正并形成可追溯的新版本。这些能力直接对应赛题的数据质量控制、来源追溯与图表数据提取要求，案例的逐维度实证见 ?? 节。

量化结论上，多模型对抗验证中十一轮的每一次错误都落在正确拦截层、受验发布中零编造行进入——该结论限定在占位符、空行、未绑定来源与结构/摘要闭合等代码可证明的检查范围，科学值的全面正确性仍需参考集核对（?? 节）；唯一穿透已修复为准入筛查（?? 节）。

参考文献

- [1] LangChain. LangGraph: Orchestrate LLM agents as stateful graphs [OL]. <https://github.com/langchain-ai/langgraph>, 2025.
- [2] Wu Q., Bansal G., et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation [C/OL]. arXiv:2308.08155, 2023.
- [3] OpenAI. OpenAI Agents SDK: Lightweight agent harness [OL]. <https://openai.github.io/openai-agents-python/>, 2025.
- [4] Shankar S., et al. DocETL: A Deeply Optimized Declarative ETL System for Complex Data [C/OL]. arXiv:2410.12189, 2024.
- [5] Shankar S., et al. Palimpsest: Optimizing AI-Powered Data Pipelines with Adaptive Declarative Programming [C/OL]. arXiv:2405.14696, 2024.
- [6] Temporal Technologies. Temporal Design Patterns: Human Approval [OL]. <https://docs.temporal.io/develop/>, 2026-08 检索.