

2026 挑战杯“揭榜挂帅”阿里云榜题

基于国产开源大模型的 AI Scientist 的研发与应用

赛题方向 赛道二-方向 1A

日期 2026 年 9 月

作品编码 611186



BioMed QAgent

面向生物医学研究的多源数据智能采集与分析系统

参赛团队信息/成员信息

作品编码: 611186

2026年度中国青年科技创新“揭榜挂帅”擂台赛 学生赛道

报名表

推报学校名称: 北京航空航天大学
揭榜标题名称: XH-202619 基于国产开源大模型的AI Scientist技术研发与示范应用
(以发榜单位对外发布的标题名称为准, 请勿改动)
榜题发榜单位: 浙江阿里巴巴云计算有限公司
申报作品名称: BioMed QAgent: 面向生物医学研究的多源数据智能采集与分析系统
申报者姓名: 汪子宸 程家麒 刘振宏 王若洋 刘梓萱 赵喆 李子木 刘恩浩
(全部成员, 按顺序填写, 且不可更改)

申报者情况	姓名	汪子宸		性别	男	出生年月	2007-06-14	
	所在学校及院系	北京航空航天大学北京学院传课书院						
	在读学历	本科	专业	工科试验班(计算与智能科学类)				
	年级	本科一年级	学制	4年	入学时间	2025		
	作品全称	BioMed QAgent: 面向生物医学研究的多源数据智能采集与分析系统						
	毕业论文题目	无						
合作者情况	姓名	性别	出生年月	学号	在读学历	年	所在学校及院系	
	程家麒	男	2007-02	1120250861	本科一年级		北京理工大学徐特立学院	
	刘振宏	男	2007-04	1120251654	本科一年级		北京理工大学徐特立学院	
	王若洋	男	2006-09	2025204059	本科一年级		青岛大学青岛医学院	
	刘梓萱	男	2006-08	2501010233	本科一年级		河海大学水文水资源学院	
	赵喆	男	2007-03	320250942491	本科一年级		兰州大学物理科学与技术学院	
指导教师情况	姓名	性别	出生年月	职称	工作单位及职务			
	石琳	女	1985-06	教授	北京航空航天大学软件学院 院长助理			
	经审核, 以上全部参赛学生作者为2026年6月1日以前正式注册的 全日制非成人教育的各类高等院校在校专科生、本科生、硕士/博士 研究生(不含在职研究生)							
	学校审核意见	学校审核意见						
	学校教务专用章	学校教务专用章						
	学校教务专用章	学校教务专用章						

2026 挑战杯“揭榜挂帅”阿里云榜题

基于国产开源大模型的 AI Scientist 的研发与应用

赛题方向 赛道二-方向 1A

日期 2026 年 9 月

作品编码 611186

BioMed QAgent

面向生物医学研究的多源数据智能采集与分析系统

参赛作品名称	BioMed QAgent：面向生物医学研究的多源数据智能采集与分析系统
参赛选题	赛道二 · 方向 1A
参赛作品简介	系统将开放式推理与确定性数据处理分开：Qwen 等 LLM 驱动的智能体（Agent）先理解研究目标、发现候选来源，并提交声明式数据需求；TypeScript Dataset Core 再负责来源登记、解析、规范化、多源整合、质量检查和正式发布。Agent 工作区中的临时 CSV 不代表任务完成。正式结果是包含数据本身、表结构、溯源信息、审计记录、验证结果、文件清单（含 SHA-256）的不可变发布件；多表结构则通过动态数据族规定表达。来源通过 SourceAsset、SHA-256 和 SourceLocator 纳入证据链。不确定映射、未知单位和低置信度抽取可以触发人在回路请求。
参赛作品使用 Qwen 大模型及 AI 技术说明	本作品提供统一的模型接入配置（API 密钥与模型名可配置），可灵活接入不同模型。在第五章的实验中，全部案例运行与图表理解均由 Qwen 系列模型承担（qwen 3.8-flash / qwen3.8-max）；主模型不支持视觉时，可单独配置视觉理解模型，用于理解页面图像进行数据提取。
作品相关文件链接	https://github.com/Lidozs55/BioMed-QAgent https://pan.quark.cn/s/fa36532492e3

目录

第一章	引言	1
1.1	科研数据整理的真实困境	1
1.2	相关工作的实际缺口	1
1.3	本系统的核心目标	1
1.4	主要贡献与核心机制	2
第二章	问题定义	3
2.1	研究问题与数据需求	3
2.2	任务边界	3
2.3	设计目标	4
第三章	系统总体组成与核心机制	5
3.1	系统组成总览	5
3.2	三层产物模型	6
3.3	研究需求编译	7
3.4	候选来源发现	8
3.5	Agent 的自主决策面	8
3.6	LLM 使用方法与上下文工程	9
3.6.1	完成规则与运行状态注入	9
3.6.2	行为约束：从实测失败模式到提示规则	9
3.6.3	路由预检与声明式工具结构描述	9
3.6.4	技能体系与专用工具	9
3.6.5	证据上下文与不确定性控制	10
第四章	确定性数据核心：八阶段流水线（Dataset Core）	11
4.1	总览：八阶段流水线与两条执行路线	11
4.2	阶段 1：正式采集与来源资产登记（acquire）	12
4.3	阶段 2：异构数据解析（parse）	12
4.3.1	图表与视觉模型	12
4.4	阶段 3：含义规范化与缺失、重复处理（normalize）	13
4.5	阶段 4-5：兼容性检查与多源整合（compat、integrate）	13
4.6	阶段 6：多表组装（derive）	13
4.7	阶段 7：校验、置信度与产品评估（validate）	13
4.8	阶段 8：不可变发布与消费时重验（publish）	13
4.9	持久化人工确认与可恢复执行（Durable HIL）	14
4.10	可靠性基座	14
第五章	实验与评测	16
5.1	评测问题与方法	16
5.2	十案例总体表现	16
5.2.1	完成情况与数据产品	16
5.2.2	运行成本与人工确认	17
5.3	跨环境对照设计	17
5.3.1	实验条件	17
5.3.2	评价指标	18
5.4	跨环境对照结果	18

5.4.1	总体比较	18
5.4.2	样例 1: 表达组学数据整合	19
5.4.3	样例 6: 文献活性与图表证据	20
5.4.4	主要发现	22
5.5	部署与视频演示	23
5.6	本章小结	23
第六章	总结与讨论	24
6.1	相较基线的收益与消耗	24
6.2	对科研数据适用性的实际意义	24
6.3	实验结果与机制验证	24
6.4	结论	25

1 引言

1.1 科研数据整理的真实困境

生物医学研究中，“找到数据”不等于找到能用的数据。一个可以直接分析的数据集，至少要回答六个问题：覆盖哪些实体和样本；数据来自哪个版本；原始文件如何变成当前字段；不同来源能否在同一层级合并；哪些值存在冲突；哪些判断需要研究者确认。现有通用智能体流程在这六个环节上都缺乏可核验的保障——其核心问题不只在效率，而在可信度。

第一，同一类研究的不同数据集，数据结构可能不一致。相同列名可能代表不同测量，不同列名也可能是同一指标；基因、变异、化合物各有标识体系。此外，表达数据存在探针级和基因级两种行层级，一行数据代表什么观测单位随层级而变；原始强度、归一化值和对数值含义不同，不能仅凭列名拼接。生物活性数据的化合物身份、实验类型和单位需要显式映射，冲突要显式记录。

第二，可读信息不等于置信的计算数据。论文中的 PDF 表格、扫描图、折线图和补充 XLSX 需要不同解析方法。视觉模型可以读图表，但模型输出本身具有非确定性——若不保留页码、边界框、模型身份、提示版本和置信度，就无法复核。

第三，人工校验修复成本高昂。常见流程是在浏览器、Excel、脚本和聊天窗口间复制内容。即使最终得到 CSV，也常缺少原始文件摘要、检索条件、字段映射、被拒绝行、冲突处理和程序版本。发现错误时，研究者难以判断应修改哪一步。

第四，一次性问答无法承担长流程状态。数据任务可能因下载、权限、人工确认或服务故障跨越多个会话。普通的对话式问答把中间状态留在模型单次能容纳的上下文窗口中，一旦超时或重启，模型容易重复下载、改变处理方式或遗忘指令。

第五，数据来源分散且异构。同一研究问题可能同时涉及 PubMed 论文、GEO 表达数据、ClinVar 变异证据、PDB 蛋白信息，以及论文附件或网页。不同平台的查询语法、分页方式、访问限制和版本标识各不相同。“相关页面”通常易于查找，但研究者难以证明是否覆盖应查来源、是否遍历分页、是否遗漏补充材料。

1.2 相关工作的实际缺口

面对数据查找与整合问题，现有解决方案可以分为四类。它们分别解决了部分问题，但各有局限。

第一类是检索与解析工具。PubMed、GEO、GDC、UniProt、ClinVar、ChEMBL 等数据库平台提供标识稳定、字段规范的入口，但跨库研究仍需手工组合查询并下载文件。规则解析器处理固定格式时容易复现，但难以覆盖布局复杂的非结构化内容；OCR 与视觉语言模型（一类可直接读取图像的多模态大模型）更加泛用，但识别精度有限，无法提供高鲁棒性数据。

第二类是整合与溯源系统。传统 ETL（抽取-转换-加载）工具擅长映射固定的输入输出结构，但难以处理运行时才确定的开放来源集合。例如，流程执行到一半发现需要补充某篇论文的附件数据时，固定管线必须先修改代码，再重排并重跑。W3C PROV、FAIR、OpenLineage 等标准描述了“溯源应当是什么样的”，但不负责生成、校验或阻止缺少溯源的发布。

第三类是 LLM 辅助系统。检索增强生成、工具调用和 ReAct 等方法使模型能在回答前搜索外部信息并调用工具。LangChain、AutoGen、OpenAI Agents 等框架把模型自报、对话结束或工具返回值当作任务完成的依据；它们通常不要求生成可重验的产物，也不会产物哈希重验失败时拒绝展示结果 [?]。DocETL、Palimpzest 等声明式 LLM 数据管线为 LLM 生成的算子与表结构提供了评估与优化手段，但这些生成物在进入最终产物前，并不经过独立于生成方的校验 [?]。Temporal、Airflow 等工作流引擎虽支持人工审批节点，但审批响应不携带证据摘要，系统无法核验人工看到的内容与待提交对象是否一致 [6]。

综合来看，上述系统分别在检索与解析、溯源标准、LLM 编排与工作流审批层面提供了成熟能力，但普遍缺少本文关注的机制：在模型输出进入正式数据之前，设置一条**信任边界**，即独立于模型、可由机器重验的校验通道。直接让模型生成或改写正式数据，仍会面临幻觉、不可重复和长流程状态脆弱等问题。本系统即围绕这一机制展开。

1.3 本系统的核心目标

BioMed QAgent 聚焦于把自然语言研究目标转换为结构化、可信的科学数据。系统生成的数据表可以直接用于分析，能够追溯来源、检查质量，并可根据反馈修正；科学结论由研究者基于这些数据作出。

系统试图解决四个连续问题：

1. **找得到**：根据研究目标定位合适的论文、数据库、附件、表格或图像数据。例如研究者需要 EGFR 突变体抑制实验的活性数据，系统能够定位目标数据库与相关补充材料，而非人工逐个站点检索。这一步由 Agent 侧的需求编译与来源发现完成（见 3.3–3.4 节）。
2. **读得懂**：把异构载体解析为明确表结构和行层级下的规范记录。论文附表、扫描图与 Excel 格式各异，系统将其统一解析到同一套表结构上。在这套结构中，字段含义与行层级明确固定：一行代表探针还是基因，由表结构显式声明，不依赖模型推断。相应工作由 Core 的解析与规范化阶段承担（见第四章）。
3. **合得上**：完成多源整合而不掩盖缺失、重复、单位差异和身份冲突。同一化合物在不同数据库中的标识可能不同，活性单位也可能分别采用 nM 与 μM ；整合显式换算可转换的量纲、记录其余冲突。这些处理由 Core 的兼容、整合与派生阶段实现（见第四章）。
4. **查得清**：将每一步的来源、输入摘要、处理版本、质量判断和人工修正一起发布。数据使用者可以沿发布清单回溯每个值的来源与处理过程；无法自动判定的差异交由人工确认，仍含未决数据的数据不会作为正式结果交付。上述机制由 Core 的校验与发布阶段以及可持久化的人工确认提供（见第四章与 4.9 节）。

系统的工程投入集中在赛题要求的核心链路：来源发现与覆盖、异构解析、清洗整合、图表提取与全链路溯源。

1.4 主要贡献与核心机制

本文将实际完成的功能归纳为四个相互关联的系统贡献。四项贡献建立在不可变产物、内容摘要、事件溯源、人工审批与模式校验等成熟构件之上，本文的贡献在于把它们组合为一条从 LLM Agent 到确定性数据核心的信任边界：智能体的开放式决策可以进入系统，但候选结果必须通过与内置路线相同的、独立于模型的校验通道，才能成为正式数据。四项贡献都建立在同一机制上：从来源字节到发布物逐文件计算 SHA-256，并在读取时重新校验，形成贯穿八阶段流水线的证据链。

确定性八阶段数据核心。系统引入 Dataset Core 组件，把全部正式数据处理固定为采集、解析、规范化、兼容性检查、整合、多表组装、校验、发布八个阶段，由注册代码执行（见第四章）。Agent 始终处于决策位——提出检索策略、表结构与变换方案，但不直接产出或改写正式数据；执行交回成熟管线，同规格重跑结果可逐字节复现，覆盖的开放不改变交付的稳定。这是后三项贡献的载体，也是系统与纯模型方案在稳定性与可复现性上的根本区别。

可验证产物与完成性绑定。1.2 节所述主流 Agent 框架判定任务完成的依据是三种信号：模型自报完成、对话结束、工具返回值。这三种信号都不要求系统生成可重验的产物，也不会产物哈希重验失败时拒绝展示；完成声明与产物实际状态之间缺少核对环节。本系统把“正式完成”定义为系统唯一承认的完成状态，其标志是一份应用层只增不改的发布物。完成规则写入系统提示，运行时逐回合注入实际进度（“尚无正式发布物”“仍有工具在执行”）；凡无法明确判定是否到达终态的情形，一律按未完成处理、拒绝宣告完成，以约束“执行幻觉”——自然语言完成声明不能替代正式终态与可重验产物。

运行时表结构的准入控制。声明式 LLM 数据管线允许模型生成新的算子和表结构，并直接进入执行与输出（1.2 节）。本系统允许未注册的多表结构“申请进入”，但申请必须通过三项准入检查。第一，输入角色明确：哪些字段来自原始数据、哪些来自变换，必须声明清楚。第二，可物化性验证：表结构必须在隔离区真实运行并产出输出。第三，输出精确完整：输出列与声明列逐一对应，无遗漏无冗余。候选文件在隔离区逐文件重算摘要；提供变换代码的一方在代码层面无法绕过或挑选校验、评估与发布模块——开放输入并未以放宽写入权限为代价。

证据绑定的人工确认机制。工作流引擎的人工任务节点通常这样设计：系统发出审批请求，人工响应同意或拒绝，系统根据响应继续或中止。问题在于，响应不携带证据摘要，系统无法验证“人工看到的内容”与“系统准备提交的内容”是否一致。本系统的每条审批请求都附带审批对象本身的证据摘要（例如待发布文件的 SHA-256 清单）；如果人工响应晚于请求，或对象在响应前已被修改，系统拒绝恢复，要求重新审批。三类高风险场景——动态发布、图表证据、浏览器证据接受——必须经过人工发布验收，该环节不可绕过。修正通过版本替代关系形成新版本，而不是覆盖旧产物，保留完整的版本历史。

2 问题定义

2.1 研究问题与数据需求

本项目要解决的核心问题，是把用户以自然语言提出的研究需求，可靠地转换为定义明确、过程可控且结果可复核的完整数据表。

用户最初输入的是一段自由文本。系统实际做的，是把需求中决定数据产品形态的信息提炼为十项明确的选择，例如交付哪类数据、表中一行代表什么、数据从哪些库取得、冲突按什么规则取舍（表 2.1）。这十项选择在实现中固化为一份数据集执行规格，即描述本次数据产品形态的机器可读配置。

表 2.1: 数据集规格的十项关键选择

选择	含义	改变意味着什么
数据产品类别	本次需要哪一类数据产品	决定交付物的整体形态
行层级	表中每行代表什么观测或统计单位	决定哪些行可以合并、哪些必须拆表
目标表结构	交付表包含哪些字段及其组织方式	决定字段级映射、类型与校验规则
实体集合	分析涉及的对象是谁、范围多大	决定采集与筛选的边界
队列与筛选条件	按什么标准纳入或排除样本	改变结果的总体与可比性
来源与采集绑定	数据取自哪个外部库或文件、采用何种访问方式	决定可溯源性
规范化配置	采用哪套标准化流程及参数	决定值含义的一致性
合并策略	多个来源出现重叠或冲突信息时按什么规则取舍	决定冲突审计的内容
验证配置	用哪些规则和阈值判断质量是否达标	决定发布标准
输出格式	最终以什么格式交付	决定下游可用性

明确这十项之后，同一份需求的执行就可以逐项核对和事后审计，不会因表述含糊而无法追因。因此在数据规格确定后，Core 层的解析、规范化与发布是确定性可复现的；而规格本身由模型生成，Agent 层的检索与纳入决策会随模型档位和采样随机性变化。在第五章中，样例 1 在 flash 与 max 两档模型下纳入的研究集合不同，即是实例。

相应地，系统交付的也不是一张孤立的数据表。合格的候选结果必须同时包含六类信息：数据本身、表结构、溯源信息、审计记录、验证结果、文件清单。候选结果只有通过全部质量检查后，系统才会生成正式发布版。正式发布只新增版本、不覆盖既有发布；读取时，系统依据发布清单重新校验文件摘要，发现文件缺失、损坏或与清单记录不一致即拒绝展示。

2.2 任务边界

本系统支持的核心任务是：给定医学研究对象和数据需求，发现并采集一个或多个科学数据来源，将其转换为统一的单表或多表结构，保留来源和处理记录，并输出便于后续分析的 CSV 数据产品。

系统的交付承诺不包含四类事项：自动提出并验证科学假设或给出医学结论、保证互联网范围内绝对查全、替代领域专家判断数据的科学含义、将模型抽取值自动升级为高可信事实。这些事项或依赖尚无明确判定标准的科学判断，或超出系统所能证明的范围，或存在把低可信抽取误当事实的风险；相应判断交由研究者结合系统交付的证据链作出。

对这些边界内的任务，系统在确定性流水线中逐项验证候选结果。只要出现必填字段缺失、单位冲突、外键错误或数据前后不一致，系统就将该候选记为验证失败。运行结果相应分为成功发布和未发布两类：成功发布时提供发布清单，供机器重新核验；未发布时不生成正式数据文件，只在运行报告中说明原因——宁可少交付，也不交付有疑问的结果。第五章的样例 10 展示了后一种结果：系统原计划把肠道微生物组与疾病关联数据整理成四张相互关联的表，但必需的差异丰度表始终为空，系统没有用空表或占位值补齐，而是停止发布，并将本次任务记为“未发布阻塞”。

2.3 设计目标

1. 可用性：输出为明确表结构下的 CSV 单表或多表，可直接进入 R/Python/统计软件或后续知识图谱流程；该性质由发布阶段的发布清单统一保证。
2. 可追溯性：每个正式来源绑定文件摘要和来源身份；记录尽可能携带可返回原载体的定位信息，为此采集阶段登记来源资产与定位信息。
3. 可靠性：解析、规范化、整合和发布由注册代码执行；缺失、重复、冲突和单位问题显式记录。
4. 可修正性：需要研究者判断时暂停并请求结构化输入；反馈后从同一任务状态恢复。
5. 可恢复性：下载等长流程操作可重试与断点续传；运行状态由事件日志留痕，重启后不重复采集或改变处理。
6. 如实呈现能力边界：工作区暂存、正式候选和已发布产品分层；系统不能以对话措辞替代发布证据，该约束由三层产物模型落实（3.2 节）。
7. 可扩展性：对成熟、高频的数据场景，系统使用预先注册的固定数据族¹；对未注册的多表结构，通过动态数据族在严格协议下提供支持。

系统重点防范以下失败：来源 URL 或版本漂移；下载中断或内容类型错误；字段映射模糊；单位、尺度或行粒度不兼容；重复与冲突被静默覆盖；模型输出缺少证据；任务重启后重复或改变处理；已被取消或超时的旧执行在事后覆盖新发布的结果；正式文件被修改后仍被展示。这些失败模式对应的机制与实测拦截记录见 4.10 节。

这些失败并非都能被自动“修复”。项目的目标是自动处理可确定性判定的问题，对无法安全判断的问题进行阻断、降级、记录或请求人工输入。

¹数据族：一类数据产品及其表结构、解析与校验规则的打包注册单位。

3 系统总体组成与核心机制

BioMed QAgent 的整体设计遵循一个核心原则：开放式理解交给 LLM，正式数据操作交给确定性 Dataset Core。两者通过声明式规格与事件日志衔接，因此“找到什么、如何解析、怎样清洗、来自哪里、输出为何种形式”都可以检查和回溯。图 3.1 给出整体分层结构，以及各层与赛题四项评分维度（数据查找完备性、来源可追溯性、清洗整合可靠性、输出格式可用性）的对应关系。

本章介绍 Core 之外的部分；Dataset Core 内部的固定流水线在第四章展开。




图 3.1: BioMed QAgent 主架构图

3.1 系统组成总览

系统由六个部分组成，Dataset Core 位于系统组成的核心，所有正式数据必须经过它的检查和发布：

- **Dataset Core**：系统唯一的数据信任边界，把数据处理固定为采集、解析、规范化、兼容性检查、整合、多表组装、校验、发布八个阶段，静态与动态两条执行路线都经它检查与发布（详见第四章）。
- **前端任务工作台**：提供需求对话、实时步骤流（思考、工具调用、进度）、人工确认对话框（批量审核、结构化修正）和发布物浏览。研究者可以从汇总结果进入具体记录或字段，逐项查看数据来源、处理过程及置信度依据（来源证据管理与发布核验界面见图 3.2）。
- **模型服务**：属于外部依赖，通过 DashScope 调用 Qwen 主对话模型和 qwen3.8-flash 图表提取模型。模型与 Agent 层不拥有正式数据的发布权。数据的生成逻辑并不都是预先写死的：在动态路线中，Agent 提出的变换代码在一个权限受限的执行区里运行，产出的候选文件必须先通过准入检查，才能成为正式数据（见第四章）。
- **Agent 层**：作为智能体运行时与可恢复运行环境，负责意图理解、来源发现与评估、证据收集，并将结果固化为数据集执行规格，提交至 Core。整个过程以事件日志留痕，并支持实时推送和下载断点续传。
- **数据源与采集通道**：包括内置生命科学库（GEO、GDC、Xena、PDB、PubChem、Reactome、ChEMBL、UniProt 等）、文献与受控 API（PubMed、GWAS Catalog、dbSNP、MGnify、openFDA 等）、用户扩展的声明式 HTTP 数据（需凭据授权）、本地导入文件，以及本地缓存。研究者可以指定偏好来源，但正式获取只由 Core 执行。
- **人工确认（人在回路，Human-in-the-Loop, HIL）**：证据绑定的人工审批贯穿系统各环节，详见 4.9 节。每一类审批对象可配置为三种档位之一：人工审批、LLM 初审（仅不通过项上报人工）、显式自动通过；初审不通过或模型调用失败时一律回退人工。动态发布、图表证据、浏览器证据接受三类高风险发布必须经人工验收，不可绕过。

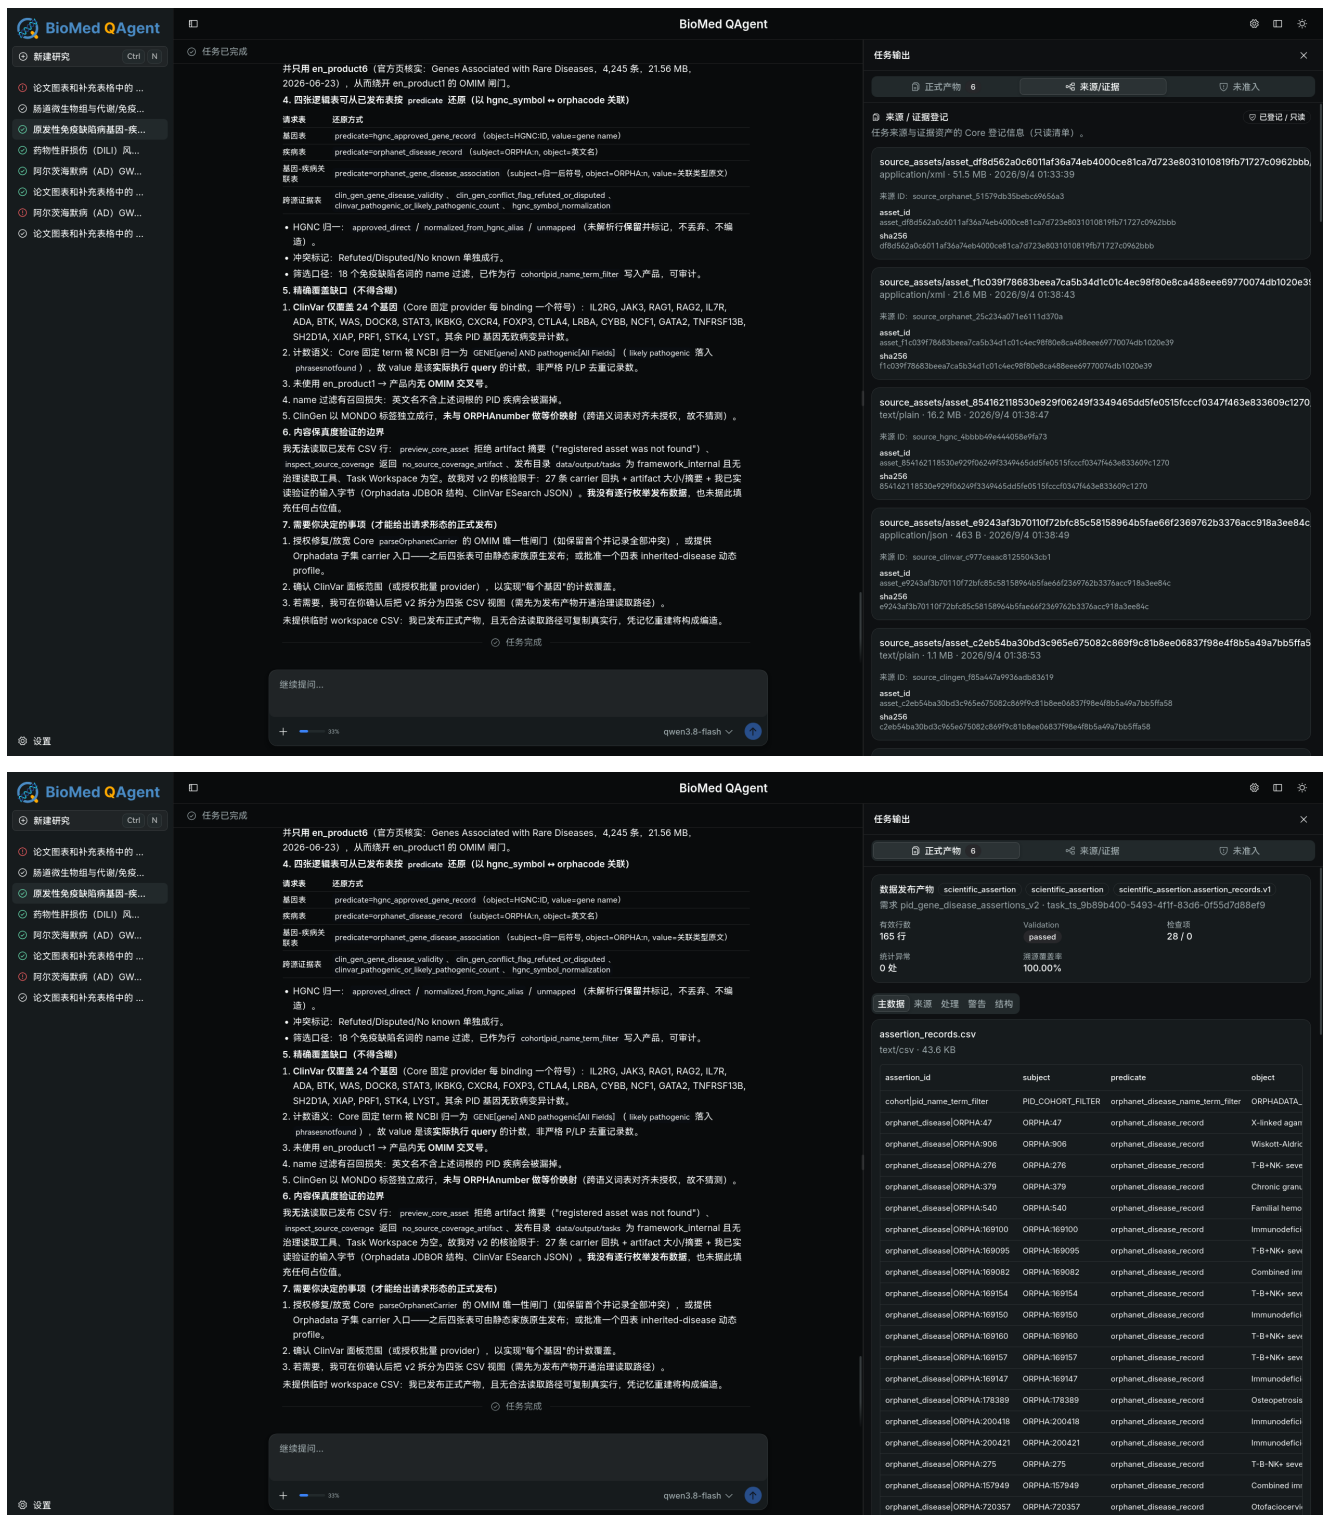


图 3.2: 前端任务工作台界面。上：来源资产注册与证据管理；下：发布产物的断言回执核验与下载入口。

3.2 三层产物模型

系统把结果分为三层：

- 工作区暂存结果**：搜索下载、模型阅读、探索脚本或暂存 CSV。它们可以辅助 Agent 开展工作，但系统不把它们当作可信数据。
- Core 候选结果**：来源已登记，处理步骤有操作回执，候选表具有表结构、溯源和验证报告，但在质量检查未通过或人工确认未完成时仍不可发布。
- 正式发布结果**：候选结果通过全部发布前检查后，系统创建只增不改的发布目录：目录内容是一个只读快照，并随附逐文件的哈希校验信息，读取时再按发布清单重新核验。目录包含数据本身、表结构、溯源信息、验证结果和文件清单（第二章）。前端工作台只把这一层视为任务完成。

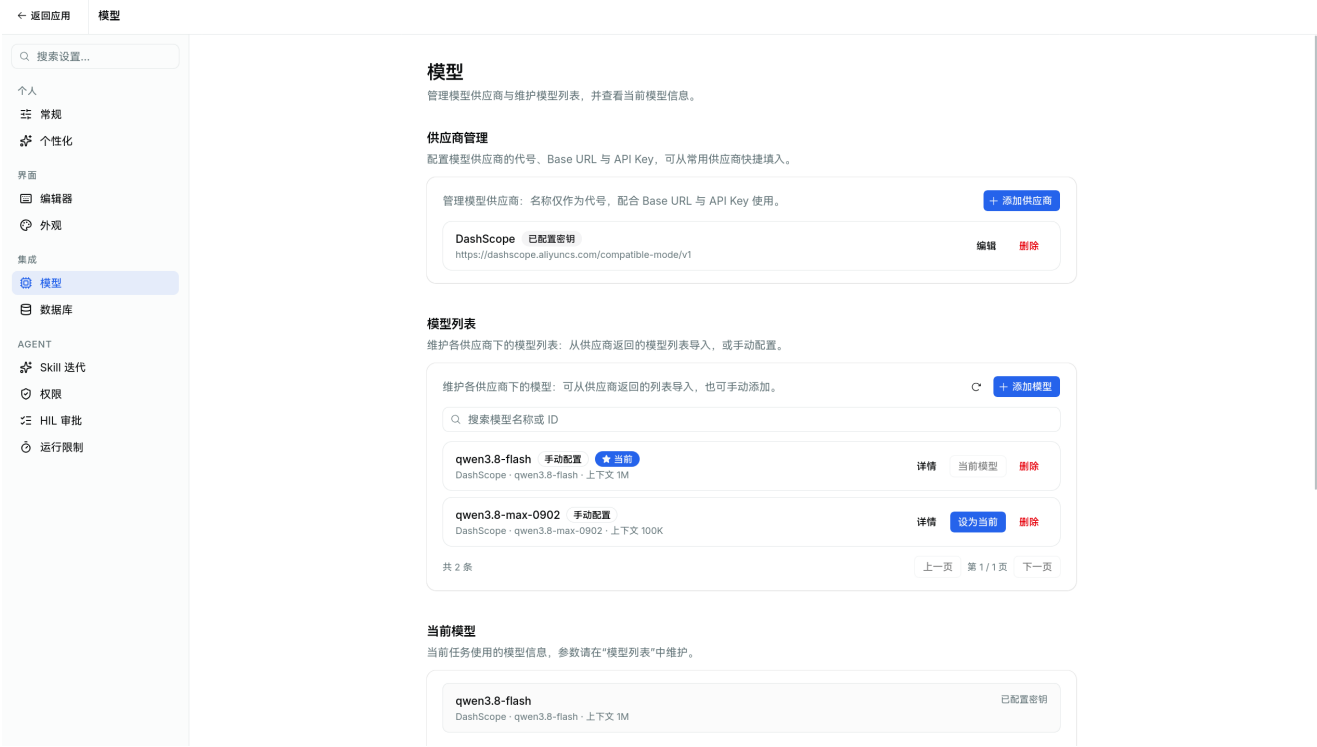


图 3.3: 模型配置界面：Qwen 模型接入配置，支持 DashScope API 密钥与模型名称灵活配置，对应系统组成中的模型服务

这一分层是项目区别于”Agent 生成 CSV”的关键，1.4 节所述可验证产物与完成性绑定也以它为基础。它把”文件存在””候选有效”和”正式可交付”区分为三个可检查状态。分层同时保留了科研工作需要的探索自由：第一层工作区不做任何检查拦截，检索、试算与脚本试错都可以直接进行；检查只发生在结果进入正式交付的通道上。这三层直接服务赛题”清洗整合可靠”和”输出格式可用”两项标准：只有到达第三层的对象才携带完整的表结构、溯源与验证信息，下游脚本可以依赖这些结构。

第一层还提供一条显式的补充通道：当正式路线因来源未准入或覆盖不足无法闭合，而用户手头已有外部文件时，系统提供任务级的不可信文件隔离区。用户经前端上传文件并声明覆盖状态（完整/部分/未知）及已覆盖与缺失的范围；服务端生成存储标识、重算字节数与 SHA-256，签发的回执显式标注该文件不具权威性、仅作不可信参考。下载时，系统按回执重新校验摘要，文件被改动即拒绝提供。隔离区只随任务目录存在与删除，独立于事件日志与发布目录；它不提供绕过候选验证与发布检查的通道，与 Core 变换准入的隔离区相互独立。这样，第一层的“不可信”就成为机器可以检查的显式标注。

3.3 研究需求编译

Agent 首先从用户问题中整理出目标实体、数据类型、样本或队列条件、必需字段、期望层级和输出要求。随后，Agent 必须执行一次路线检查：查询服务端登记的能力清单（注册表），确认它支持哪些数据族、表结构、来源与解析器的组合，以及动态路线能直接绑定哪些数据提供者。

需求编译是 Agent 的第一项智能工作：把一句自由文本研究目标翻译成机器可执行、可逐项核对的规格。以样例 1 为例，输入只有一段“乳腺癌肿瘤与正常组织转录组整合”的任务描述，编译产物必须落定几项关键抉择：交付物取表达数据长表；行层级取探针级，并映射到基因级；目标实体取肿瘤/正常配对样本；来源绑定为 GEO 系列及其平台注释；规范化配置包含探针-基因映射与样本分组元数据；输出为可直接进入统计软件的单表。自由文本中所有含糊之处（如用哪个平台、纳入哪些样本、一行代表探针还是基因）都在这一步变成显式决定。

服务器会交叉校验这份规格：数据族与表结构是否已注册；行层级与目标实体层级是否一致；每个来源绑定的提供者、解析器和参数是否合法；规范化、合并和校验配置是否在允许的配置清单内；输出格式是否受支持；多表输入的角色关系是否闭合。任一项不通过，系统都会阻断执行或要求修正。

路线指执行数据构建的固定路径：静态路线使用注册表中现成的数据族与解析器；动态路线允许 Agent 为未注册的多表结构临时申请一条受控执行路径。如果注册表能够精确表达需求，Agent 采用静态路线。如果静态结构不匹配，但所有输入都能由 Core 的提供者获取（或已经是任务拥有的来源资产），Agent 可以采用动态路线。两条路线都无法闭合时，系统只交付明确标记为暂存的结果，并列出缺失的正式能力，不会把

这类结果当作正式发布来呈现。

3.4 候选来源发现

来源发现由 Agent 的查询策略和专用工具共同完成。系统采用多路并行检索：文献 API、专业数据库、补充材料归档和通用网页搜索并行，同一主题再用不同通道的结果相互印证。查询策略按通道分工：文献通道以主题词与同义词扩展检索论文及其补充材料，数据库通道按标识符与字段精确查询，网页通道用于发现预置通道之外的官方入口。当同一事实能被两个相互独立的通道分别检索到时，系统提高对该来源的采信优先级；仅被单一通道检索到的来源，先列入待核对清单。当前代码覆盖文献、表达组学、变异、药物与生物活性、蛋白与通路、微生物组及通用网页等通道。发现阶段的输出是候选编号（accession）、论文、数据集、附件和下载入口，以及对其字段和范围的初步理解。

来源发现的自主性在样例 8 的一次重跑中有直观体现。这次任务（药物性肝损伤）中，官方 DILIrank 文件持续返回 404。Agent 没有停留在反复重试上，而是经受控浏览器访问搜索引擎结果页，从命中记录中找到 LiverTox 官方通道，先后完成 16 次页面读取与 13 次取证下载，并对 5 组 openFDA 不良事件查询作交叉核对，全程没有请求权限，也没有人工提示。与之配套的是一条止损规则：浏览器通道对同一主机的连接失败连续达到阈值后，立即中断该通道，返回结构化的“无数据”信号。早期运行曾观测到 Agent 对同一失效地址连续枚举 555 次的无效循环，这条规则正是为阻断此类行为而设。

为了判断在预先定义的问题子领域内查到了哪些来源，系统设计了来源覆盖证据。Core 按执行规格中的每个来源绑定逐项生成检索计划，并把自身核实过的采集结果汇总为覆盖结果；两者写入一份结构固定的覆盖报告，Agent 按同一结构读取。记录内容包括四部分：检索计划，绑定来源、提供者、解析器和参数；采集回执，按绑定统计的行数与拒绝及排除原因；检索观察，查询式、状态、结果数和请求上限；汇总信息，来源总集（universe）规模、成功/失败/未尝试数量和集成行数。覆盖缺口直接驱动补源行为：某个绑定失败或未尝试时，Agent 优先在同类通道内换用独立来源，而不是重复同一查询。

覆盖统计只限于检索计划内的逐源覆盖——这是完备性中可由第三方逐项复核的部分；遗漏整个数据源（如未绑定的数据库、未发现的补充材料库）属于整库查找完备性问题，由任务级核对评估、不计入该指标，因为脱离检索计划的“查全”无法核查。对预置通道之外的数据，系统有三条接入路径：声明式 HTTP 数据源（用户扩展并授权）、浏览器导航与页面取证、任务级文件隔离区；新来源经登记后进入统一的来源与覆盖统计。当前静态路线发布时，来源覆盖证据等审计记录会列入发布清单，随只增不改的发布目录一并交付，Agent 可直接读取发布物中的这些记录。

3.5 Agent 的自主决策面

Agent 与 Core 的分工可以概括为：Agent 负责开放式的研究决策，设计数据产品；Core 负责按确定性规则实现设计，并验证其是否可以交付。Agent 的自主性体现在数据产品生产的各个决策点上（表 3.1）。Core 约束的是这些决策进入正式数据的通道，而不是决策本身：它拒绝执行期的任意流程编排（DAG，有向无环图）——Agent 不能在运行中提交自定义的处理节点链、合并函数或发布路径；而数据模型层面的多表设计（表、主外键与角色映射）归 Agent 决定。

表 3.1: Agent 的自主决策清单

决策点	Agent 自主决定	Core 的约束
检索与来源	在文献 API、专业数据库、补充材料归档和网页等通道间组合查询策略，评估并排序候选来源，决定采集对象和顺序	正式采集由注册提供者执行，来源字节登记为按内容摘要标识的任务资产
执行路线	路线检查后选择静态家族或动态路线；静态结构不匹配时，从零设计多表结构规格，规定表、主外键、角色映射与来源绑定	规格须通过预检与限定准入检查；候选文件经隔离区逐文件重算摘要
规格迭代	依据预检的结构化错误自主修正设计，直至收敛	拒绝理由逐字段点名、可操作；不通过即不执行
质量与修正	自检候选或已发布版本并决定重提、降级、阻断与续跑策略	显式换版保留版本历史；高风险发布按策略人工确认

决策点	Agent 自主决定	Core 的约束
数据值	提出字段映射、单位换算与抽取值的候选	正式数据值由注册操作产出；动态路线的候选须经与内置路线相同的逐级检查（见第四章）

3.6 LLM 使用方法与上下文工程

本节说明 Dataset Core 之外的 Agent 侧如何使用 LLM 以及如何组织上下文，对应 1.4 节的可验证产物与完成性绑定。证据上下文控制（3.6.5 节）与第四章的确定性校验上限和人工确认机制直接衔接。

3.6.1 完成规则与运行状态注入

Agent 的系统提示将“任务完成”定义为可验证状态，而不是自然语言自报。对于数据生产请求，Agent 必须先检查可用的执行路线；只有取得本次运行产生的不可变正式发布物及其发布清单，才能报告正式成功。若只能形成工作区 CSV，就必须标记为暂存，并说明正式路线未能闭合的原因。该规则针对三类常见错误判断：把工具预览当成“数据集已完成”，把工作区文件当成“正式发布”，以及对失败来源保持沉默并宣称“已完整检索”。

完成判定也有提示词之外的支撑。运行时每回合注入一条由事件流压缩而成的运行状态，内容包括当前阶段（规划/执行/等待工具/收尾）、工具调用成败计数、是否已存在不可变发布物，以及下一步建议。例如：“仍有 N 个工具在执行，不要假定其结果”；“最近一次失败为某工具，仅在可重试或换用独立来源时重试”。

3.6.2 行为约束：从实测失败模式到提示规则

系统提示词中的行为约束来自对模型失败模式的实际观察。开发期在同一个表达组学案例（乳腺癌 GEO 表达整合）上的提示词迭代记录显示，轻量模型在无人工干预的长流程中反复出现三类行为偏差。其一，时限幻觉：某次运行在 240 回合的预算中仅使用了 35 次模型调用，却以“由于时间限制和复杂性”宣布放弃并等待用户指示，而系统从未设置任何时限。其二，同参数重复失败：对同一数据集以同一套参数连续失败七次，仍不改变策略或换用其他来源。其三，发布后反复自检：正式发布完成后，模型反复重读已经验证过的回执，一次运行中这部分重复验证消耗了全部计费 token 的 79%。

系统提示词针对这三类行为逐条写入约束。其一，声明系统不设真实的墙钟时限，回合与上下文预算只是防止失控的保护性上限，不允许以时间不足为由放弃任务。其二，同一错误重复出现时，立即停止同形态重试，改为查明被拒绝的具体原因，或换用真正独立的来源。其三，每件发布产物只验证一次，验证后记录结论并转入最终报告。决策方式也作了相应调整：不确定某个工具或检查如何运行时，直接阅读它的实现源码，以代码为准判断“接受什么输入”，而不是凭记忆反复试错。

在一组前后对照的迭代中，同一案例、同一模型、同一任务的工具调用从 60 次降到 36 次，计费 token 从 5.71M 降到 3.73M，工具错误从 7 次以上降到 2 次。迭代中也识别出一些值得保留的行为模式，如单平台同粒度设计优先、拒绝跨研究拼接行、发现映射未经验证时主动修订而不是宣称完成；这些模式随后写入流程技能，成为后续运行的默认规则。该迭代发生在第五章评测之前，用于校准提示词，不计入评测结果。

3.6.3 路由预检与声明式工具结构描述

BioMed QAgent 向大模型公开当前真实能力及相关参数。静态路线要求精确匹配注册表中的数据族、表结构与来源能力清单；动态路线只接受预检报告确认可以绑定的输入。工具参数的结构描述严格约束字段类型、枚举、对象结构和必要参数，服务器端还会进行交叉验证。

上下文工程的重点不是把所有代码放进提示词，而是提供模型决策所需的最小必要信息。这些信息包括：当前任务与研究目标；可用工具及其严格输入结构；注册表返回的数据族、表结构和提供者能力；来源搜索结果与失败回执；校验问题、人工确认选项及证据摘要；当前发布物或阻塞状态。这样可以把“模型知道什么”绑定到运行时的实际能力，减少提示词与代码版本之间的漂移。

3.6.4 技能体系与专用工具

专用能力以技能形式组织，当前共 25 项，分为三类。技能体系解决的是来源覆盖广度问题：把高频生命科学数据源的入口、查询语法与特有字段的访问方式工程化，各项技能复用统一的工具调用与审计框架，其输出同样经由第四章的信任边界进入正式数据。

其一，数据库类技能 14 项，覆盖 3.4 节所列各库 (PubMed、GEO、GDC、Xena、UniProt、PDB、PubChem、ChEMBL、ClinVar、GWAS Catalog、dbSNP、MGnify、openFDA、Reactome)，封装对应入口的查询、分页与来源特有字段，Agent 不必为每个站点编写脚本。

其二，载体与取证技能：包括浏览器导航与页面取证、PDF 表格提取、图表视觉提取 (qwen3.8-flash)、文献理解、网页视觉取证、搜索发现、GitHub 文件取回和本地缓存复用。

其三，流程技能：包括数据集构建引导、研究数据指引和统计分析。前两类技能回答“可以使用哪些工具”，流程技能则回答“如何把需求做成合格的数据产品”：数据集构建引导把“先做路线检查，再构造并校验数据集规格，最后以正式发布物为唯一完成依据”的执行规定固化给 Agent；研究数据指引按主题提供数据源选择、清洗和可分析性判断的方法，并要求明确声明“查了哪些源、哪些相关源没有查”；统计分析把差异表达、热图与相关性等常用分析固化为工具，其产出不创建也不取代正式发布。第四章各阶段能获得合格输入、第五章各案例能在无人工逐步指令的情况下收敛完成，都以前两项流程技能为前提。

技能是声明式的：扩展数据源只需描述来源与字段，不绕过网络策略、资产登记或注册解析器；工具层返回结构化结果与错误，Agent 据此调整查询或报告缺口，底层 I/O、权限与数据变换保持可审计。

3.6.5 证据上下文与不确定性控制

模型不应仅看到最终值，还应看到该值的来源类别、定位信息、解析层级和置信度。对于非确定性抽取，系统记录该值的置信类别及其判定理由、执行抽取的模型与提示版本，以及是否经过人工复核，并在 Core 中设置可信度上限。

字段映射和单位修正也采用相同原则：模型可以提出候选，但只有注册规则或绑定证据的人工决定可以改变正式数据。

4 确定性数据核心：八阶段流水线（Dataset Core）

4.1 总览：八阶段流水线与两条执行路线

BioMed-QAgent Dataset Core

确定性数据处理流：从受控输入到不可变数据产品

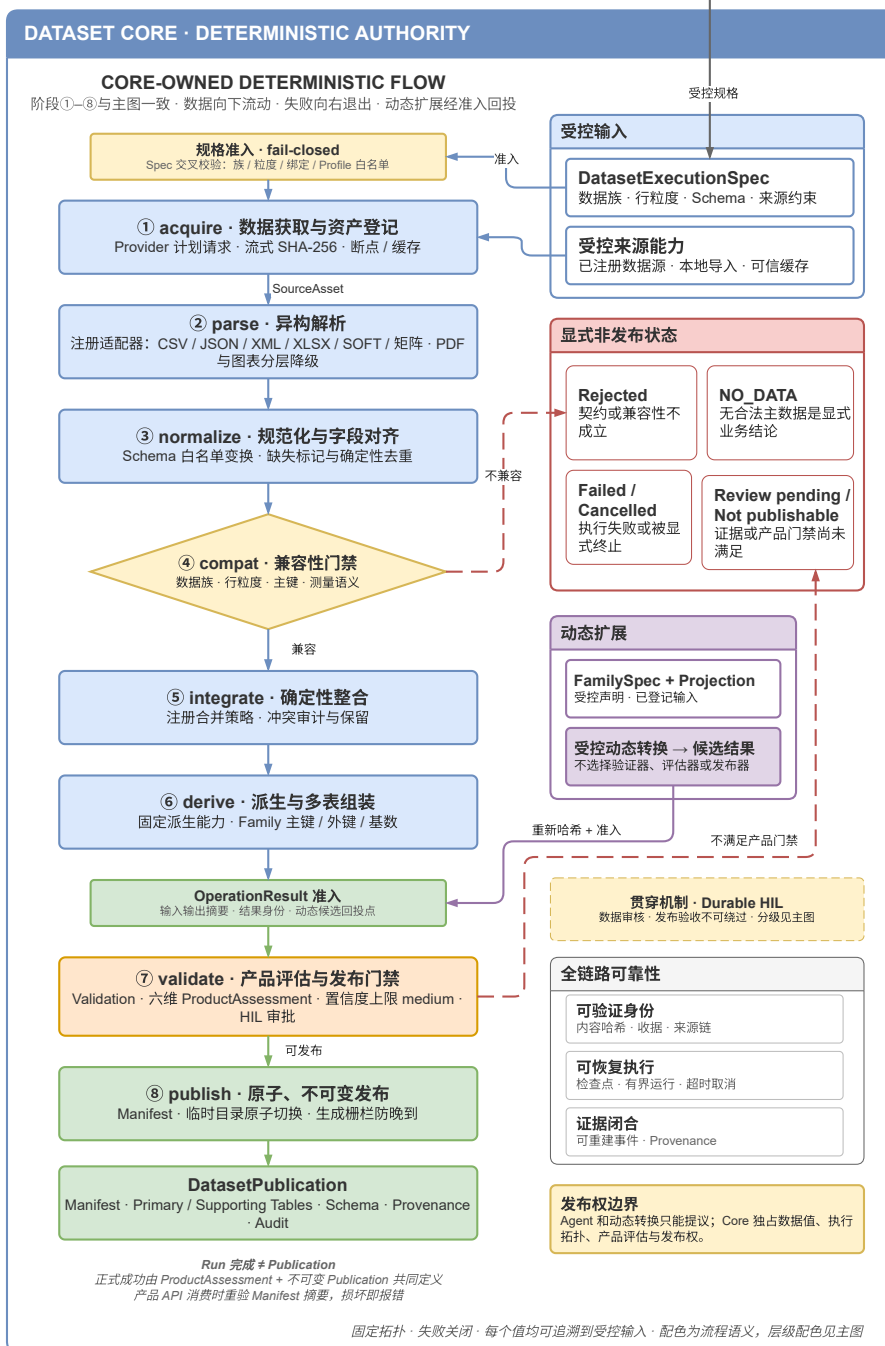


图 4.1: Dataset Core 确定性数据流详图

与校验规则；动态数据族扩展的是系统能读的数据范围，并不放宽向正式数据写入的权限。

动态数据族的接入走一条固定的准入协议，通过准入后与静态家族接受完全相同的后续检查。第一步，Agent 提交数据集执行规格，声明多表结构、各字段来源角色与来源绑定，服务器预检确认输入可以由注册提供者获取；第二步，变换代码在权限受限的执行区真实运行并产出候选文件，隔离区对候选逐文件重算内容摘要；第三步，准入检查核对输入角色声明、输出表头与声明列精确一致、输出与摘要闭合，任何一处不符即整体拒绝；第四步，通过准入的候选进入与静态路线相同的完整性校验、产品评估与发布检查。协议把

Dataset Core 是系统唯一的数据信任边界。它将数据处理固定为八个阶段：采集、解析、规范化、兼容性检查、整合、多表组装、校验、发布；每个阶段的输入、输出摘要与执行凭证都留痕可查。本章先说明流水线的整体形状与写入约束，再按阶段说明各环节对数据质量的实际作用；Agent 的自主决策面见 3.5 节。

流水线内部有两条执行路线（图 4.1）。A 路线使用已注册数据族的固定操作骨架；B 路线处理动态规格：表结构、字段映射与变换代码由 Agent 在运行时提出，变换代码在一个权限受限的执行区里运行并产出候选文件，隔离区与 Core 通过重新计算摘要、检查闭合条件对候选统一校验。候选文件要成为正式数据，必须依次通过准入检查、完整性校验、多表产品评估与发布器的逐级检查，任何一级不通过即整体拒绝。

写入侧的约束是结构性的：变换方不能挑选校验、评估或发布模块，变换产出的表头哪怕只与声明相差一个字段，隔离区也会拒绝该候选。但准入检查只核对输入、输出与摘要的结构闭合，不验证变换代码的语义正确性—计算错误的变换同样能通过检查，数值是否正确依靠变换审查与事后抽查。也就是说，可靠性主要来自预先编写的注册表、解析器

开放收敛到提交这一个受控环节：Agent 始终处于决策位——决定建什么表、用什么变换，但不直接产出或改写正式数据；执行由成熟管线承担，覆盖的开放不改变交付的稳定，这是动态路线能够既放开覆盖又保住稳定性的关键。

系统用明确的结束状态区分“运行完成”与“正式发布”：终态分为 Rejected（拒绝）、NO_DATA（无数据）、Failed（失败）与 Cancelled（取消）四类，凡无法明确判定为成功的运行，一律不产生发布物。内容筛查有一条真实记录：筛查上线前，曾有一次“占位符空壳”（用占位值冒充真实数据的候选）穿透全部检查进入发布；筛查上线后未再发生。

4.2 阶段 1：正式采集与来源资产登记 (acquire)

Agent 的来源发现拿到 URL 后，正式路线不会直接信任工作区中的任意文件。Core 的统一下载设施按预定的请求定义执行网络访问，实施访问策略、大小与超时限制、重试、断点续传和内容缓存。文件写入任务专属目录后，来源资产注册表流式计算 SHA-256，把任务、来源身份、内容摘要、媒体类型与采集实现身份绑定为一份输入证据，支持时还记录快照或修订号等版本信息。“来源资产”因此不是一个本地路径，而是可复核的输入证据。

4.3 阶段 2：异构数据解析 (parse)

正式静态路线使用已注册的解析器，把来源特有的 CSV、JSON、XML、XLSX、SOFT、矩阵或 API 响应转换为数据批次，同时输出解析统计、被拒绝的记录和溯源定位信息。解析器的原则是**失败而不猜测**：遇到来源格式异常时，解析器应失败或将问题写入审计记录，而不是让模型猜测缺失字段。

表达数据的解析集中体现行层级纪律：GEO 既可能提供基因级结果，也可能只提供探针级矩阵，系统不会在缺少可信注释时把探针当成基因——一行代表探针还是基因，由表结构显式声明。GDC 与 Xena 的输入形态不同，但都必须转换到目标表达表结构后才可合并。

论文衍生的载体单独处理：PDF 表格解析保留页面与位置证据（页码、边界框、题注）；无框线表格与跨页表头仍是启发式解析难点，这类解析结果需人工核对。图表走视觉模型通道（4.3.1 节）。

4.3.1 图表与视觉模型

赛题要求的“自动识别图表坐标轴或图例解析错误”由确定性规则层承担。图表工具采用多层降级策略：优先通过 qwen3.8-flash 理解页面图像或嵌入图像，失败后尝试解析 PDF 表格，仍失败时只提取图表标题作为有限信息。

视觉提取的能力边界只有一条：模型转录图内印出的数值标注，不从曲线或图形趋势上读取数值。因此，没有印出标注的图不进入数据交付—提示词转而要求 Agent 检索原始数值来源（正文表格、补充材料、出版社 source data、作者仓库），系统对这类图至多以文字简报汇报总体趋势。这里的“失败”指模型调用或解析出错；返回内容格式正确但数值错误时不触发降级，由点级复核把关。每个抽取结果必须携带模型名，每个数据点必须附带置信度及其判定原因，其可信级受 4.7 节确定性上限的约束，不会因模型自报高可信而自动成为正式真值。

在规范侧，视觉语言模型 (VLM)、PDF 表格或标题抽取的结果先作为结构化图表证据进入系统，形成带点级取值与来源绑定的证据资产，再进入生物活性测量数据族。样例 6 的正式发布即由这条链路产出：活性值、实验、论文、补充材料、图系列与图点 6 个数据表，另有表结构、溯源与质量评估，共 9 件产物。该轮运行中，图系列与图点两表为不含数据行的空表：视觉模型通道未产生可确认的图表数值，系统不以估计值补齐，而是以空表如实登记、在其余条目上完成交付——这正是发布前检查拒绝不可确认图表数值的一个实例（条目化评分见第五章）。组装前，系统逐点核对来源并复核证据，无法确认的图表数据不纳入正式数据；复核未通过或表缺失时写入图表证据检查结果并阻止发布。人工修正保留原始值并记录修正步骤；样例 6 实验中的 5 次人工确认包括 3 次受控来源访问授权和 2 次发布验收。

图表系列表记录轴名、轴单位、刻度与图例文本；轴/图例与每个数据点各带抽取模型声明的校验状态（含义明确、含义不明、已经人工确认，数据点的“精确”表示该值是图内印出的标注值）。系统用确定性规则核对声明与点数据的一致性：声明为“精确”的点，其对应轴或图例一旦标为“含义不明”即直接判失败；反之，只有轴或图例明确标为“含义不明”时，才允许系列省略点数据。轴/图例状态被误报为“含义明确”时不在此规则的覆盖范围内。点级复核通过后的自动采纳与人工修正两条路径都按上述要求产出正式发布物，该链路已通过点级样例测试。

4.4 阶段 3：含义规范化与缺失、重复处理 (normalize)

规范化器依据目标表结构完成类型转换、字段命名统一、实体标识表达和必要的值标准化。核心原则是：只有目标表结构和规范化配置明确授权的变化才可以自动执行；规范化保留原始写法与规范值之间的血缘，便于任何一处转换被事后复核。缺失与重复按类型分层处理：必填字段缺失时拒绝或阻断，可选字段缺失保留为空并计入完整性统计；完全重复按确定性键去重，主键重复且值一致时合并血缘、保留多来源；每类处理均保留对应证据。

实体身份对齐同样采用确定性机制：化合物以 InChI Key 精确匹配建立交叉映射表，匹配不上时显式标记为冲突而不强行合并；基因符号归一使用内置确定性映射表；探针到基因的映射依赖逐平台注释资产，未映射探针保留原命名空间，不静默丢弃。这些注释资产与来源文件同样按内容摘要登记，映射结果随发布件交付。

4.5 阶段 4–5：兼容性检查与多源整合 (compat、integrate)

解析与规范化产物进入整合前，兼容性检查核对各批次在数据族、表结构、行层级、实体层级、单位、含义和尺度上是否可以合并，并据此生成确定性的合并域键——由值的含义、尺度与单位，加上物种、特征命名空间、测量类型、规范化状态与参考版本等维度构成，任何一维不一致都不能进入同一合并域。未知单位或不受支持的数值尺度不会被自动修正：单位换算只有在有注册转换公式时执行，公式限定为线性安全形式；没有注册规则时阻断或交人工选择。

整合器按注册的合并策略合并批次，并在以先登记来源为准的权威行上汇总血缘和置信度。主键重复且值冲突时，一律保留先登记来源的行作为权威行——先到先得，保证裁决可复现——落选来源、冲突键与双方取值写入冲突审计并随产物交付，必要时阻断；实体身份冲突保留交叉映射表；值一致时合并血缘并保留双来源标记。最终取哪个值为真，留给研究者复核或改判——整合层的产出是可复核的记录，而不是替研究者定案。

4.6 阶段 6：多表组装 (derive)

对于需要多实体关系的数据，数据族的组装阶段生成多表候选，并检查主键、外键、基数和表角色。¹

单表与多表是规格层的可选形态：需求是单一层级观察时交付单表（如样例 8 的 FAERS 不良事件计数），需求横跨多个实体层级时才拆分多表。以生物活性数据为例，测量值表 (activities) 按声明的外键关联实验条件表 (assays) 与化合物规范身份表 (compounds)，并辅以靶点表、来源表与交叉映射表 (图 4.2)，避免将不同层级的观测合并进冗余度很高的单张宽表。多表发布清单记录表、关系、溯源引用和置信度引用，下游按清单声明的显式关系连接各表，而不是凭同名列猜测连接键。

4.7 阶段 7：校验、置信度与产品评估 (validate)

校验配置在发布前检查候选结果，范围覆盖九个方面：表结构与字段类型；必填字段完整性与允许缺失率；主键唯一性与外键基数；实体标识命名空间；单位与数值尺度；溯源与来源定位覆盖；置信度记录与最终行对齐；产物摘要闭合；可复现所需的输入与实现身份。多表产品评估从结构、关系、标识、溯源、置信度和可复现性六个维度评价产品：无阻断项时判定为“可发布”；只存在可复现性方面的阻断项时，评级至多为“已验证”（低于“可发布”）；存在其余五个维度（结构、关系、标识、溯源、置信度）的阻断项时判定为“不完整”。这使得“CSV 能打开”与“数据产品含义上闭合”不再是同一件事。


置信度按证据类型受到上限约束：确定性、受版本约束的解析可以获得包括 high 在内的较高可信等级；VLM、LLM、OCR 和网页抽取等非确定性来源最高封顶为 medium。封顶为 medium 的记录可以逐条提交人工审核，但不会自动进入审核—图表审核仅对低置信度记录发起 (4.9 节)，因此 medium 置信度的 VLM 数值可不经人工复核进入正式发布，准确性由事后来源级抽查保障。置信度是证据类型的确定性分级，作用是决定各环节的放行标准与复核安排，而不是模型自报的校准概率。验证结论与结束状态绑定：空主数据、兼容性失败或验证失败的结果一律不可发布。

4.8 阶段 8：不可变发布与消费时重验 (publish)

发布者把质量检查合格的候选复制到独立目录，生成发布清单，逐文件记录相对路径、媒体类型、字节数和 SHA-256；发布经临时目录原子切换完成，执行锁与代次围栏（见 4.10 节）保证超时或已取消的旧执行不能

¹主键：表中每行的唯一标识。外键：表中指向另一张表主键的字段，如测量表中的化合物编号指向化合物表。基数：两表间一条记录与另一表几条记录的对应关系。表角色：各表分别承担记录测量值还是提供规范身份。

activities 按清单声明的外键多对一关联 assays 与 compounds · 组装阶段检查主键 / 外键 / 基数 / 表角色



关系由数据家族清单显式声明：cardinality = many_to_one · missing_policy = reject (引用缺失即拒绝组装)

图 4.2: 生物活性数据的多表组装：activities 经外键多对一关联 assays 与 compounds

晚到覆盖新结果。产品 API 在每次读取时重新核验清单与文件摘要，文件被改动或损坏即拒绝展示。这里的“不可变”是应用层语义：正常 API 只追加发布、不覆盖旧版本；它不等同于抵御操作系统级改写的密码学防篡改。

4.9 持久化人工确认与可恢复执行 (Durable HIL)

人工确认不是系统的默认手段，而是最后一道环节：仅在注册的确定性规则与候选推理（例如单位换算先查询注册公式表，命中后自动应用）无法安全定案时，才就字段映射多候选、单位或测量含义未知、探针到基因映射歧义、低置信度图表点、冲突记录保留策略等情形创建结构化请求。

请求携带逐项候选值、置信度、相关记录、证据摘要以及任务、运行与需求身份；前端以“在候选与证据概要上选择”为主，以自由修正为辅（通过/拒绝/修正）。只有证据摘要和任务身份都匹配时，响应才能恢复原操作。

按审批对象划分，人工确认覆盖三类：工具许可与凭据授权（通过/拒绝）、数据审核（字段映射、单位、图表与网页证据）和发布验收。审批档位按对象配置为人工审批、LLM 初审（仅不通过项上报人工）或显式自动通过，初审不通过或模型调用失败时一律回退人工。高风险产品（动态发布、图表证据、浏览器证据接受）的发布验收不可绕过：对应对象强制人工审批，配置其他档位会被直接拒绝，只有人工接受后系统才执行发布；普通静态数据发布不统一要求发布验收，这与“Core 独占发布权”相互配合。

4.10 可靠性基座

八个阶段运行在共同的可靠性基座上。表 4.1 逐项给出机制定义与实测或设计依据：

表 4.1: 可靠性基座：机制与实测或依据

机制	一句定义	实测或依据
执行锁	同一任务同一需求的发布互斥； 目录原子锁，单机多进程有效	并发执行不能同时覆盖同一发布目标

机制	一句定义	实测或依据
代次围栏	发布前复核本次执行的租约（对执行权的限时持有凭证），超时或已取消的旧执行不得在事后覆盖新结果	机制由执行租约与取消路径测试覆盖
超时与取消事件溯源	每个操作有界，取消即时生效 全部操作追加事件日志，状态可由日志重建	操作超时与取消路径由测试覆盖 自然语言完成声明不能替代正式终态与发布记录
Durable HIL	审批请求与决策均持久化保存；恢复执行时按原调用重放，全程不再调用 LLM	机制与三档审批见 4.9 节
内容摘要与重验	逐件 SHA-256；读取端每次读取重算，不匹配即拒绝展示	正式案例全部产物经监督程序逐件重验一致 (5.1 节)

5 实验与评测

本章回答三个问题：第一，系统能否在不同类型的数据任务中形成正式数据产品；第二，正式发布机制能否把来源、质量检查和交付文件绑定在一起；第三，与通用智能体环境相比，专用数据管线在运行成本、需求覆盖和可审计性上表现如何。前两个问题由十案例总体测试回答（5.2 节）；第三个问题由两个代表性案例的跨环境对照回答，对照环境为通用智能体平台 Qoder（5.3 节）。全部评测遵循 5.1 节的评测范围与统计标准。

5.1 评测问题与方法

十个案例覆盖表达组学、变异、靶点证据、蛋白结构、生物活性、论文图表、GWAS、药物安全、罕见病和微生物组数据。BioMed QAgent 接收研究任务描述，自主完成来源检索、数据处理、质量检查和发布；每个案例的输入只有对应的任务描述原文（TOPIC.txt），不含任何附加提示。系统记录任务起止时间、模型用量、工具调用、人工确认和终态；成功任务还需逐件校验发布文件的大小和 SHA-256。一个运行单元指一次从任务提交到终态的完整运行；运行内部的重试或多次执行尝试不另计为运行单元。

评测采用三类指标。第一类是**完成性**：形成正式发布物记为成功；因必要数据或质量条件未满足而阻断记为未完成，并单独保留阻断原因。第二类是**运行成本**，包括端到端时长、模型 token 和工具调用。第三类是**数据产品质量**，从需求覆盖和证据可审计性两方面评价：需求覆盖衡量任务要求完成多少；可审计性衡量结果是否保留来源标注、记录级定位、文件清单、处理方法、质量检查和原始证据。文件摘要一致用于确认交付完整性，不能替代科学内容核验。

十个案例统一采用 qwen3.8-flash 作为基座模型运行；为观察模型档位的影响，样例 1 与样例 6 另在 qwen3.8-max 上各运行一次。

评测范围与统计标准。本轮共 12 个运行单元，每个实验条件运行一次，属单次观察：结果用于描述系统能力与呈现环境间差异，不支撑统计显著性或单机制因果检验。科学事实准确性与计划外查找完备性的量化按参考集对照评测进行——以冻结参考集对发布物核对行级覆盖率、字段命中率与数值一致率；本轮的计划内覆盖统计与样例 1 的两环境抽样互查（5.4.2 节）是其先行核对。

5.2 十案例总体表现

5.2.1 完成情况与数据产品

表 5.1 汇总十个案例。样例 1–9 均形成正式发布数据，覆盖从单表表达数据到多表证据产品的不同形态；样例 10 因必需的差异丰度数据未能满足发布条件而停止，没有把不完整的候选文件提升为正式数据。

表 5.1: BioMed QAgent 十案例运行结果

案例	研究任务	终态	主要数据产品	时长 / token
样例 1	乳腺癌肿瘤与正常组织转录组整合	成功发布	GSE86374 肿瘤/正常表达长表 (GPL6244 探针到基因映射), 5,294,223 行, 校验通过	26 min / 5,952 K
样例 2	LUAD EGFR 突变表达双层级整合	成功发布	GSE31852 基因水平表达长表 (GPL6244 探针映射), 4,128,828 行、124 样本, 校验通过	19.2 min / 1,401 K
样例 3	EGFR NSCLC 靶点多源证据整合	成功发布	UniProt 靶点、ClinVar 变异与 ClinicalTrials 试验等多源证据表, 校验通过	31.1 min / 5,099 K
样例 4	Spike-ACE2 结构、序列与变异证据	成功发布	Spike 与 ACE2 蛋白注释证据表 (UniProt 记录级定位), 校验通过	8.5 min / 1,864 K
样例 5	EGFR 抑制剂活性与化合物结构整合	成功发布	ChEMBL 活性表 (100 行) 及化合物、实验、靶点维表, 校验通过	28.8 min / 3,869 K
样例 6	EGFR 突变体抑制实验与论文证据	成功发布	6 个数据表及表结构、溯源和质量评估, 共 9 件	98.9 min / 6,915 K

案例	研究任务	终态	主要数据产品	时长 / token
样例 7	阿尔茨海默病 GWAS 风险位点整合	成功发布	风险位点与变异-基因映射分别发布	36.2 min / 6,350 K
样例 8	药物性肝损伤风险药物证据整合	成功发布	openFDA FAERS 断言与研究数据	45.9 min / 10,646 K
样例 9	原发性免疫缺陷基因-疾病证据整合	成功发布	动态基因-疾病证据产品，共 5 件	351.2 min / 8,529 K
样例 10	肠道微生物组-疾病关联整合	未发布阻塞	两次执行分别因分类映射表和差异丰度表为空被拒，0 件正式产物	108.5 min / 23,168 K

本表为结果总览：终态沿用成功发布、未发布阻塞与失败或取消的三分类标准；各案例的运行成本与人工确认在 5.2.2 节展开，样例 6 的产物结构与质量细节在 5.4.3 节展开。逐案例的事件流、发布清单、逐件 SHA-256 重验记录与人工复核记录随项目资料完整保留，可按案例逐项核查复现。

从产品形态看，系统既能处理数百万行表达数据，也能组织结构、活性和疾病证据等多表产品。样例 3-5 展示了跨数据库实体对齐，样例 7 与样例 9 展示了运行时表结构对开放来源集合的适配。样例 10 虽未完成交付，但终态和阻断原因均被明确记录，说明完成判定取决于正式数据产品，而不是模型的自然语言声明。样例 4 的证据表仅 2 行，反映该次运行对该主题只采集了少量蛋白注释证据，其检索范围以运行记录为准。

样例 10 是唯一的未发布阻塞案例，其失败过程值得完整说明。运行记录显示：部分来源可追溯的候选文件曾成功暂存，但任务要求的“队列限定差异丰度”补充表在两轮采集与解析中均为空表；静态路线执行“四表全有或全无”的组合约束，两次拒绝将该候选提升为正式数据，运行最终以未发布阻塞结束。仅凭这一结果，无法区分“来源中本来就不存在该数据”与“系统检索或解析能力不足”，需要领域专家核查；对应的改进方向，是扩充差异丰度类来源通道与解析器覆盖，并为多表产品提供可配置的部分交付机制。系统在此案例中保守地拒绝了不完整交付，但任务本身没有完成。

5.2.2 运行成本与人工确认

运行特征从时长、token、模型调用和人工确认四个维度观察。十个案例各有一次以 flash 为基座模型的运行（下称 flash 运行），样例 1 与样例 6 另各有一次 max 运行，共 12 个运行单元；其中 11 个形成正式发布物，样例 10 的 flash 运行因必需数据缺失保持未发布，运行级发布率为 91.7%。

运行成本方面，flash 运行的耗时介于 8.5-351.2 分钟、token 消耗介于 1.4M-23.2M：样例 9 用时最长（351.2 分钟）；样例 10 的 token 消耗最高（23.2M），工具调用达 264 次，但因必需数据缺失，最终保持未发布。两次 max 运行分别耗时 30 分钟（样例 1）与 78 分钟（样例 6）。模型调用方面，样例 7-9 的 flash 运行行为 40-66 次模型调用、65-88 次工具调用；样例 6 max 仅用 29 次模型调用和 54 次工具调用完成发布，少于同案例 flash 运行的 41 次与 71 次。

人工确认方面，12 个运行中仅样例 6 的两次运行触发人工确认（flash 5 次、max 4 次，采用 LLM 初审的 HIL 设置），其余 10 个运行均为零。运行中出现的个别工具报错都由 Agent 按重试规则自行恢复，没有累积成运行失败。

上述结果体现了两项技术特征。其一，发布检查与任务终态绑定：只有形成并通过检查的数据产品才计为成功。其二，系统对长任务保留可观测的成本和状态，即使任务未发布，也能定位成本集中在哪些阶段，为后续优化采集与解析能力提供依据。

5.3 跨环境对照设计

Qoder 是阿里巴巴推出的面向真实工作的 Agentic 平台 [7]，可作为通用智能体环境的典型代表。本节以相同的核心任务与模型档位，对 BioMed QAgent 与 Qoder 进行对照测试，以观察专用数据管线在运行成本、需求覆盖和可审计性上是否较通用环境具有优势。

5.3.1 实验条件

样例 1 考察 GEO 转录组的研究筛选、样本元数据、平台注释、探针-基因映射和表达数据交付；样例 6 考察 EGFR 突变体活性记录、论文与实验信息、补充材料和图表证据。BioMed QAgent 使用 qwen3.8-flash 与 qwen3.8-max；Qoder 使用相同命名档位的模型，但完整推理配置未随导出文件提供。每个案例的四个观察

单元共享核心任务与 CSV 交付目标，模型档位只在同一环境内比较。

为对等比较，BioMed QAgent 的约束已内置于系统提示词，Qoder 侧的提示词也作了相应调整，双方均为调校后的配置。计量方式上，Qoder 侧的时长与 token 由人工读取并记录，BioMed QAgent 侧由系统自动统计，两环境的计时标准与计量方式并不一致；因此跨环境成本仅在数量级层面可比，不作精确数值对比。

BioMed QAgent 侧以正式发布作为成功条件，数据表必须连同来源、表结构和质量状态通过发布检查；Qoder 侧以核心 CSV 交付物齐备作为完成交付，任务条目的满足程度另行计入覆盖评分。两种交付形态按同一套指标检查需求覆盖和证据可审计性；Qoder 的交付为工作区文件，本系统的交付为正式发布物，交付形态差异在 5.4 节单独比较。

5.3.2 评价指标

表 5.2 给出统一指标。两个质量维度对四个观察单元采用同一套评分规则，每个案例按“覆盖评分、可审计性评分、交付形态与来源定位、成本与边界”四步展开。

需求覆盖：按本案例的任务条目清单逐项评分，完整交付计 1 分，部分交付计 0.5 分，完全缺失计 0 分，以得分占条目总数的比例计分。条目清单来自各案例的任务要求（样例 1 为七项，见 5.4.2 节；样例 6 为六项，见 5.4.3 节的评分标准）。比例不低于 2/3 为高，不低于 1/2 且低于 2/3 为中，低于 1/2 为低。

证据可审计性：统一使用六项清单：来源标注、记录级定位、文件清单、处理方法、质量检查和原始证据。对四组交付逐一评分，每项 0–1 分（完整记 1，完全缺失记 0，部分满足按完备程度取中间值），取六项均值，再按同一分档映射：不低于 0.67 为高，不低于 0.50 且低于 0.67 为中，低于 0.50 为低。

样例 1 与样例 6 的任务条目不同，覆盖的原始分数只在同一案例内比较，三级评价用于跨案例展示；案例特有的补充维度（如样例 6 的结构化覆盖与复用性）单独标注，不进入跨案例比较。

表 5.2: 跨环境比较指标

维度	定义	数据来源
运行时长	任务提交至终态的端到端时间	运行事件或会话记录
token 消耗	模型调用的 token 总量	模型用量记录
需求覆盖	按任务条目核对已完成、部分完成和未完成内容	交付文件与条目核对表
证据可审计性	来源、定位、清单、方法、质量检查和原始证据的完备程度	发布记录或交付包

5.4 跨环境对照结果

表中以 B 表示 BioMed QAgent，以 Q 表示 Qoder；组记法“档位·环境”如 flash·Q。

两个案例按同一框架分析：先按任务条目清单给出需求覆盖分，再按六项清单给出证据可审计性分（5.3.2 节），然后比较交付形态与来源定位，最后讨论成本、交付边界与运行稳定性。

5.4.1 总体比较

表 5.3: 八个观察单元的运行成本与质量评价

案例	模型	环境	终态	时长	token	覆盖	可审计性
样例 1	flash	B	成功发布	26 min	5,952 K	高	高
样例 1	flash	Q	完成交付	168 min	52,940 K	高	高
样例 1	max	B	成功发布	30 min	4,182 K	高	高
样例 1	max	Q	完成交付	35 min	4,474 K	高	高
样例 6	flash	B	成功发布	98.9 min	6,915 K	中	高
样例 6	flash	Q	完成交付	175 min	67,912 K	高	高
样例 6	max	B	成功发布	78.0 min	7,511 K	高	高
样例 6	max	Q	完成交付	46 min	5,160 K	高	高

表 5.3 的覆盖列按 5.3.2 节的条目清单计分：样例 1 四组得 6–6.5/7，均为高；样例 6 四组得 3.5–5.5/6，其中 flash · B 为中，其余为高，逐项判定见 5.4.3 节的评分标准。可审计性列按六项清单计分，四组均为高。

总体上，八个单元均形成可检查的交付物。BioMed QAgent 的四个单元均完成正式发布，并将数据、表结构、来源和质量结果作为一个整体交付。样例 1 flash 中，BioMed QAgent 用时 26 分钟、消耗 5,952 K token，约为 Qoder (168 分钟、52,940 K) 的 1/6.5 与 1/8.9；max 档两者成本接近 (30 对 35 分钟、4,182 对 4,474 K)。样例 6 flash 中，BioMed QAgent 用时 98.9 分钟、消耗 6,915 K token，约为 Qoder (175 分钟、67,912 K) 的 1/1.8 与 1/9.8；样例 6 max 中 Qoder 更快也更省 (46 对 78 分钟、5,160 对 7,511 K)。

样例 1 的总量差距主要由交付规模贡献：BioMed QAgent flash 交付 1 个研究，Qoder 交付 16 个研究并含单研究差异分析与跨研究元分析。样例 1 为大批量数据处理工作，运行时长对性能和网速敏感；文中样例 1 的测试均在同一网络环境和同一机器上运行，以控制这一波动。按交付研究数归一，Qoder 每研究约 10.5 分钟、3.3M token，低于 BioMed QAgent 的 26 分钟、6.0M token；max 档归一后同样是 Qoder 更低 (约 8.8 对 15 分钟、1.1 对 2.1M token)。样例 6 中 Qoder 的交付量不小于 BioMed QAgent (主表 10,682 行外加维表)，其 flash 档成本差距不受交付规模影响。两个案例的成本对比见图 5.1。




图 5.1: 样例 1 与样例 6 八个观察单元的运行时长与 token 对比。

图 5.1 中，按总量统计时两个案例的 flash 档 BioMed QAgent 均低于 Qoder，max 档互有高低。样例 1 的总量差距主要由交付规模贡献——Qoder flash 纳入 16 个研究、max 纳入 4 个，而 BioMed QAgent 两档各发布 1 个研究；摊薄到单个研究后，Qoder 更低 (flash 约 10.5 对 26 分钟、3.3 对 6.0M token，max 约 8.8 对 15 分钟、1.1 对 2.1M token)，样例 1 的总量优势在按交付研究数归一后不再成立。样例 6 不存在这一统计标准问题：Qoder 的交付量不小于 BioMed QAgent (主表 10,682 行外加维表，无法按研究数折算)，故其 flash 档的总量差距不受交付规模影响，更接近同等交付规模下的执行效率差异。

八个单元的总比较可以归纳为三点：其一，完成标准不同——BioMed QAgent 的四个单元均以通过发布前检查的正式发布物交付，数据、表结构、来源和质量结果作为整体接受检查；其二，成本差异需要区分统计口径——样例 1 的总量优势在按交付研究数归一后不再成立，可信的成本结论是样例 6 flash 档 (时长约 1/1.8、token 约 1/9.8，且交付量不小于对方)；其三，本系统的稳定优势不在成本，而在来源绑定、发布前质量检查与逐件可校验的交付形态，这两点在后面两节按案例展开。

5.4.2 样例 1：表达组学数据整合

评分标准。需求覆盖按七项任务条目评价：研究纳入、差异表达、样本元数据、平台注释与探针-基因映射、探针水平数据、基因水平数据，以及分析可用性与来源标注。研究纳入项评价是否给出明确的检索、筛选与纳入结果。两名评审独立核对四组交付，其中三组评分一致；另一组——flash · Q——的探针水平数据只覆盖 16 个纳入研究中的 5 个，经复核按部分完成计分，最终为 6.5/7，其余三组均为 6/7。该评分以任务条目为分母，衡量交付对条目的满足程度，不度量来源查找完备性；两环境纳入研究数的规模差异见表 5.4 与正文说明。证据可审计性按 5.3.2 节的六项清单对四组交付评分，两环境的差异在“来源定位与质量证据”段定性展开。

表 5.4: 样例 1 四组数据产品比较

组	纳入研究	样本元数据	探针水平	基因水平	证据组织
flash · B	1 (GSE86374)	GSM 分组支撑表	与基因级融合于长表	5,294,223 行	记录级来源定位与发布校验
flash · Q	16	3,226 行	5 个研究宽表	13 个研究宽表与汇总	URL、MD5、检索日期和筛选记录
max · B	2	GSM 分组支撑表	GSE139038 长表	GSE86374 长表	记录级来源定位与发布校验
max · Q	4	443 行	4 个研究宽表	4 个研究宽表	URL、MD5 与质量日志

交付形态与数据组织。四组产物表现出两种不同的数据组织方式。Qoder 为每个研究输出宽表，每行对应探针或基因、每列对应样本，便于直接进入 R 或 Python；BioMed QAgent 发布长表，每个样本的每个探针或基因各占一行，并保存记录级来源定位，适合逐行核验和跨来源复用。Qoder flash 纳入 16 个研究，BioMed QAgent flash 发布 1 个研究，max 发布 2 个研究；只有 Qoder flash 进一步交付了单研究差异分析和跨研究元分析。

来源定位与质量证据。BioMed QAgent 的优势主要体现在三个方面。第一，来源定位与发布清单形成机器可核验的证据链，抽样记录能够定位到原始压缩文件中的具体行。第二，编码、数值类型、单位、行边界、映射和溯源等检查在发布前执行，两档运行的发布检查均通过。第三，系统保留源文件数值精度：在样例 1 flash 的 GPL6244 探针集合中，33.3% 的探针没有基因注释，这些记录被原样保留并标明未映射，而不是静默删除或猜测填补。对两个环境共有记录的抽样核对显示，数值差异来自显示精度，例如 BioMed QAgent 的 4.1862 在 Qoder 中显示为 4.186；该核对为两环境间的抽样互查，未对照原始来源。Qoder 以 URL、MD5 和检索日期支持人工复核，BioMed QAgent 则进一步提供记录级定位和发布文件校验。

成本、交付与边界。样例 1 flash 中，BioMed QAgent 用时 26 分钟、消耗 5,952 K token；Qoder 用时 168 分钟、消耗 52,940 K token，前者分别约为后者的 1/6.5 和 1/8.9。max 档两者成本接近。BioMed QAgent 两档均未执行差异表达，纳入研究数也少于 Qoder；记录级溯源还带来存储开销，例如 GSE86374 的规范化日志约 0.6 GB。总体而言，样例 1 对照显示，BioMed QAgent 在 flash 档以较低成本提供了更细的来源绑定、数值保真和发布前质量控制，Qoder 则在研究覆盖和分析便利性上略突出。

运行稳定性。在 Qoder flash 运行中，系统发生两次异常中断，由人工手动恢复后继续运行。

5.4.3 样例 6：文献活性与图表证据

样例 6 的需求覆盖与证据可审计性两项评分沿用 5.3.2 节的统一框架。

评分标准。需求覆盖按六项任务条目评价，条目由任务描述原文逐项派生：E1 论文记录，从公开论文中定位 EGFR 突变体抑制实验数据并保留论文标识；E2 变异谱，记录涉及 wild-type、L858R、T790M 或 L858R/T790M 突变体；E3 实验对象标注，每条记录保留实验对象（细胞系或表达体系）；E4 图表曲线数据，图表中的剂量-反应曲线数据；E5 补充材料，补充表格中的数据及材料定位；E6 定位与置信度，每条记录保留论文、图表或表格定位、单位和抽取置信度。四组交付均按上述条目逐项核对交付物与证据包计分，结果见表 5.5。

表 5.5: 样例 6 需求覆盖的条目化评分（每项满分 1，合计满分 6）

条目	flash · B	flash · Q	max · B	max · Q
E1 论文记录	1	1	1	1
E2 变异谱	1	1	1	1
E3 实验对象标注	0.5	1	1	1
E4 图表曲线数据	0	0.5	0	0.5
E5 补充材料	0	1	0.5	0.5
E6 定位与置信度	1	1	1	1

条目	flash · B	flash · Q	max · B	max · Q
合计（分档）	3.5/6（中）	5.5/6（高）	4.5/6（高）	5/6（高）

计分中的关键判定如下。E4：BioMed QAgent 两档运行的正式发布物中，图表系列表与图表点表均为不含数据行的空表——视觉模型通道未产生可采纳的图表数值，系统在发布前检查中拒绝以估计值补齐，该条目记 0；Q flash 从多剂量表格聚合出 7 条曲线、16 个点（交付自述为表格数值聚合而非像素数字化），记 0.5；Q max 对 6 条剂量-反应曲线完成识别并如实标注未数字化，记 0.5。E5：BioMed QAgent flash 的补充材料登记表为空，记 0；max 登记并解析了 1 件补充材料 PDF（含成员级 SHA-256），记 0.5；Q flash 保留 473 条补充材料访问记录及未解析清单，记 1；Q max 以图件与补充表格核验清单记录识别状态、未取回材料本体，记 0.5。E3：BioMed QAgent flash 的实验表中 32/43 条实验对象字段为表格行片段而非规范标注，按部分交付记 0.5；其余三组实验对象或变异标注完整，记 1。该评分以任务条目为分母，衡量交付对条目的满足程度，不度量来源查找完备性。

在此之外，本案例对 Qoder flash 与 max 两份离线导出另设一个案例特有的补充维度——结构化覆盖与复用性（X），由模式分解、标识符归一、单位归一、可复用维表、清单完整性和拒绝记录六项等权组成，每项 0–1 分取均值，分档沿用统一阈值；该维度仅用于解释两份导出在数据组织上的差异，不进入表 5.3 的覆盖列，覆盖列取值来自本节上方的条目化评分。表 5.7 列出 X 与证据可审计性（Y）的子项得分。

表 5.6: 样例 6 Qoder 离线导出的补充评价（X 为结构化覆盖与复用性，案例特有维度；Y 为证据可审计性，子项为统一六项清单在本案例的细化）

模型	X	Y	位置	判定依据
flash	0.950	0.808	高覆盖–高可审计	22 个 CSV 的结构分解充分；10,682 条事实对应 10,215 个来源位置
max	0.500	0.758	覆盖中档下界–高可审计	主表结构紧凑、清单完整；6,439 条事实对应 11 个来源位置

表 5.7: 样例 6 Qoder 二维评价的分项得分

X 分项	flash	max	Y 分项	flash	max
模式分解	1.00	0.30	溯源非空率	1.00	1.00
标识符归一	1.00	0.50	溯源粒度	1.00	0.65
单位与剂量归一	1.00	0.90	清单哈希可验证	0.60	1.00
可复用维表	1.00	0.10	质量检查可复算	0.85	0.80
清单完整性	0.70	1.00	方法日志深度	1.00	0.70
拒绝与排除记录	1.00	0.20	原始证据留存	0.40	0.40
均值	0.950	0.500	均值	0.808	0.758

Qoder flash 的结构化覆盖与可审计性均为高；Qoder max 的可审计性为高，结构化覆盖为 0.500，恰在中档下界。表 5.8 再从交付结构与证据组织两个方面比较四组产品。

表 5.8: 样例 6 四组数据产品的结构与证据组织

组	数据结构	证据与质量检查	交付特点
flash · B	活性值、实验、论文、补充材料与图表等 6 个关联表	记录级来源绑定；发布文件逐件校验	9 件产物作为一个正式版本发布
flash · Q	10,682 行事实表，并含筛选、排除、访问和参考维表	来源定位细；多数质量检查可复算	结构覆盖最充分；清单有 1 处自指摘要不一致

组	数据结构	证据与质量检查	交付特点
max · B	6 个关联表及表结构、溯源与质量评估	94 项检查全部通过；发布文件逐件校验	29 次模型调用、54 次工具调用完成正式发布
max · Q	6,439 行事实表、来源登记与方法日志	清单 5/5 通过；来源定位粒度较粗	结构紧凑，并纳入 145 条 GtoPdb 策展记录

交付形态与数据组织。两份 Qoder 主表都包含记录编号、突变体、化合物、ChEMBL 标识、活性类型、纳摩尔值、细胞系、来源数据库、检索日期、抽取方法和置信度等核心字段。flash 主表为 $10,682 \times 109$ ，还提供 pXC 值（活性浓度的负对数，如 pIC50 一类）、跨源一致性、化合物身份解析、证据文本以及表格行列坐标；max 主表为 $6,439 \times 35$ ，结构更紧凑，并额外纳入 145 条 GtoPdb（IUPHAR/BPS Guide to Pharmacology Database，药理学指南数据库）策展记录。flash 还把单剂量筛选、非浓度指标、排除记录、拒绝候选、补充材料访问、未解析附件和参考维表拆为独立文件，说明其结构化覆盖维度（X）的高分来自结构分解和复用能力，而非单纯文件数量。

来源定位与质量证据。来源粒度进一步区分了两套产品。flash 的 10,682 条事实对应 10,215 个不同来源位置，包括 ChEMBL 活性标识、表格行列坐标、证据文本和补充材料工作表定位；max 的 6,439 条事实只有 11 个不同的来源定位值，其中 6,285 行共享同一说明。因此，两者来源字段均非空，但 flash 更接近记录级定位，max 更接近来源批次级定位。

在清单与质量检查的复算方面，两份离线产品呈现互补优势。两份 Qoder 导出包自带的清单分别采用 SHA-1 前缀与 MD5，本节复核以各交付包自身清单为准，仅作完整性对照。flash 的 22 个文件在行数、列数和字节数上全部匹配，21/22 个 SHA-1 前缀可验证，但清单自指行摘要不匹配，且摘要仅保留 16 位十六进制前缀；其 16 条质量检查中，记录唯一性、正值范围、pXC、一致性分类和来源计数均可精确复算，部分以代表性突变-药物组合中位数作合理性检查的声明只能复现相对高低方向、无法精确复现数值，原因是其筛选条件没有完整披露。max 的 5 个清单条目 MD5 全部验证通过，行列数和来源非空声明也可复算；其限制主要是少量极端值需要结合可靠性字段筛选。两份离线产品都没有包含方法日志所引用的数据库原始响应、论文附件或图表文件，也没有包含提取脚本，因此不能在离线条件下完整重放处理过程。

成本、交付与边界。BioMed QAgent 两档均把 6 个关联数据表、表结构、溯源和质量评估作为一个不可变发布件交付（表关系与发布结构见图 5.2）。表 5.8 中的 9 件产物均指各运行的当前正式版本；flash 曾发布一个较早版本，随后由当前版本替代并保留版本关系，替代的具体过程见随项目归档的运行事件记录。max 运行用 29 次模型调用和 54 次工具调用完成 94 项质量检查。与 Qoder 相比，BioMed QAgent 的优势不在文件数量，而在正式发布身份、统一质量检查和产物级证据绑定；Qoder flash 则在结构覆盖、参考维表和排除审计上表现突出。

5.4.4 主要发现

跨环境结果体现了 BioMed QAgent 的四项技术优势。

1. **完成性由正式数据产品判定。**BioMed QAgent 的四个对照单元均形成正式发布物，数据文件与表结构、来源和质量结果共同接受检查，避免把临时文件或自然语言完成声明当作最终交付。
2. **质量控制进入执行链。**样例 1 的未映射探针被显式保留，样例 6 的多表关系和发布文件接受统一检查；质量状态不是事后附加说明，而是发布条件的一部分。
3. **证据组织支持机器复核。**BioMed QAgent 将记录级来源定位、文件摘要和发布版本绑定在同一数据产品中。相较仅提供工作区文件，这种组织方式更适合长期复核、修正和复用。
4. **flash 轻量档的效率优势（限样例 6）。**样例 6 flash 档中，BioMed QAgent 的运行时长约为 Qoder 的 1/1.8，token 约为 1/9.8，且 Qoder 的交付量不小于本系统，成本差距与交付规模无关，与确定性管线替代模型探索式操作的分工相符。样例 1 flash 的总量差距（时长约 1/6.5、token 约 1/9）在按交付研究数归一后反转（Qoder 每研究约 10.5 分钟、3.3M token，低于本系统的 26 分钟、6.0M token），由交付规模差异解释。两案例均为单次观察，比较精确到数量级（统计标准见 5.1 节）。

对照实验说明的是专用数据管线在正式交付与证据可核验上的优势，以及通用环境在部分任务上的覆盖和分析灵活性。



图 5.2: 样例 6 正式数据产品的表关系与发布结构。

5.5 部署与视频演示

随报告提交的视频演示展示了一次从零开始的独立部署与运行，验证系统不依赖开发环境即可安装和使用：

- 1. **安装与启动**：从 GitHub 下载正式 release 并启动，无需源码构建与开发工具链；
- 2. **模型配置**：在前端设置界面自行配置 qwen3.8-flash 模型与 API 密钥（配置界面见图 3.3）；
- 3. **完全人工审批下的运行**：将 HIL 审批档位配置为完全人工，运行样例 7（阿尔茨海默病 GWAS 风险位点整合）并产出正式发布物；期间触发一次人工确认，流程暂停并在人工处理后继续，直至发布完成；
- 4. **外部数据源扩展**：将 ClinicalTrials.gov 配置为外部数据源接入，并以提问“2 型糖尿病目前有哪些临床试验？给出 3 个 NCT 编号、题目和状态”作简单验证，确认系统能正确调用该库，返回的试验记录包含 NCT 编号、题目与状态（对应 3.4 节所述预置通道之外的数据接入路径）。

其中第 3 项记录了完全人工审批档位在真实运行中的实际执行过程：5.2.2 节的 12 个评测运行采用 LLM 初审设置或未触发人工确认，本演示覆盖了完全人工档位的确认与恢复路径。

5.6 本章小结

十案例测试中，系统完成 9 个正式发布，并在必要数据不满足条件时明确阻断 1 个任务。全部运行的成本与状态统计表明，系统能够对长任务持续记录成本、状态和人工确认，并把成功终态绑定到可校验产物。跨环境对照中，BioMed QAgent 的四个观察单元均完成正式发布；效率优势限于样例 6 的 flash 档，样例 1 的总量差距在按交付研究数归一后主要由交付规模差异解释（5.4.2–5.4.3 节）；两个案例中本系统均提供了较完整的来源绑定与发布前质量检查。在本次评测范围内，系统表现出与设计定位一致的行为：智能体负责开放式数据工作，确定性数据核心约束正式交付。

6 总结与讨论

6.1 相较基线的收益与消耗

本文以“纯人工整理”和“纯 Agent 问答”两条路线为基线。表 6.1 总结了本系统带来的收益及新增消耗。

表 6.1: 相较两条基线的收益与消耗

基线	本系统的收益	新增消耗
纯人工整理	消除多库重复查询与下载、 手工复制对列与统一缺失值、 逐条查证来源与版本、 人工检查主外键/重复/冲突、 中断与错误后的重做，以及 为下游补写表结构与来源说明	token 与模型调用费用（Agent 推理、qwen3.8-flash 图表抽取）； 来源文件、审计与发布物的存储； SHA-256 与验证的计算开销； 数据 API 访问费用； 模糊映射与冲突的人工审核； 新数据源接入的一次性适配
纯 Agent 问答	把对话输出升级为可复用、可核验的数据产品： 确定性可复现； 来源与版本证据； 发布前质量检查与冲突审计； 可恢复、可修正——而纯 Agent 的自由改写难以稳定复现，中断后往往整体重来	高于“一次问答”的模型与验证开销； 产物持久化与维护； 流程中的人工介入点（纯 Agent “先回答后纠错”完全自助，但没有质量保证）； 数据族表结构、解析器与校验配置的一次性投入

因此，项目的价值不在于“消除人工”，而是将人工从重复搬运转向对科学含义、不确定性和冲突的高价值核对，并使核对结果能够持续复用。

6.2 对科研数据适用性的实际意义

对研究者而言，正式发布物比聊天答案更接近可以纳入科研流程的数据对象。它可以直接供脚本读取，具有明确的表结构、来源和质量说明，并可在发现错误时定位和修正。对团队协作而言，发布清单和版本替代关系降低了“每个人手里有一份不同 CSV”的风险。

对后续知识图谱、统计分析或证据推理而言，多表关系和溯源提供了比复制宽表更稳定的输入。上述意义成立有一个前提：系统在交付正式产物的同时，明确交付能力边界说明。

6.3 实验结果与机制验证

第五章的评测揭示了三个关键事实，三项系统贡献（1.4 节）也在评测中得到实际执行与验证；其中人工确认仅在样例 6 的两次运行中触发。

运行终态与字节级验证。十二个运行单元（十个 flash 运行与样例 1、样例 6 的两个 max 运行）中，11 个形成正式发布物并通过产物回执与 SHA-256 重验，运行级发布率为 91.7%；样例 10 以未发布阻塞结束，没有把缺少必需差异丰度表的暂存结果提升为正式产物。十二个运行均形成明确终态，本次实验中没有出现“没有正式产物却判定成功”的情况。

轻量模型效率优势（样例 6）。样例 6 的 flash 档对照显示，BioMed QAgent 用时约为 Qoder 的 1/1.8，token 约为 1/9.8，且 Qoder 的交付量不小于本系统，该差距与确定性管线承担数据操作、模型调用集中于理解与抽取的分工相符；样例 1 flash 的总量差距在按交付研究数归一后反转，由交付规模差异解释（第五章）。该对照为两个完整系统的单次运行比较，机制级归因属消融实验，是后续工作方向。

证据可审计性存在差异。BioMed QAgent 的正式产物具有发布回执、SHA-256、溯源与产品评估记录；样例 6 的 Qoder 离线导出具有来源列、文件清单和质量检查日志，但两个数据包都缺少其方法日志所引用的原始数据文件与处理脚本，flash 档清单还有一处摘要不一致，max 档的 6,439 行数据只有 11 个不同的来源定位。这些记录使两个产品的审计条件可以逐项比较。

在机制层面：**确定性八阶段数据核心**的执行由第五章全程记录——11 个运行单元发布成功、样例 10 因必需数据缺失阻断，全部正式产物经逐件 SHA-256 重验一致，同规格重跑可直接比对，验证了“执行由注册代码承担、结果可复现”的设计；**可验证产物与完成性绑定**即上述终态结果——成功与发布物一一对应；**表结构准入控制**表现为样例 7 分别形成风险位点与变异-基因映射两个动态数据产品、样例 9 在固定结构不能满足数据约束后切换到动态数据族并完成发布——这一贡献的权衡（预置可靠性对开放覆盖，见第四章）随之显形，两个动态案例均运行在 Core 既有提供者之上，跨领域开放场景的独立处理能力是后续评测方向；**人工确认与证据绑定**表现为样例 6 flash 的 5 次人工确认中，3 次为受控来源访问授权、2 次为发布验收，第二次发布明确替代第一次发布并保留版本关系，展示了敏感操作授权和发布验收在同一证据链中的作用。flash 运行采用 LLM 初审档位、按策略仅上报不通过项，其初审准确率未在本轮测量，可结合参考集对照评测一并标定。

6.4 结论

BioMed QAgent 针对赛题“从科学问题到可用数据”，建立了一条从自然语言需求、来源发现、正式采集、异构解析、字段规范化、多源整合与校验，直到不可变发布的处理链路。

这套链路的关键，在于把模型放在适合开放式推理的位置。Agent 作为数据产品的设计者提出检索策略、来源选择、多表规格和修正建议；正式数据变更则交给 Dataset Core 的来源绑定、解析、规范化、验证与发布检查。这一分工降低了模型自报或自由生成直接成为正式数据的风险；来源错误、解析器缺陷或验证规则覆盖不足仍无法因此消除，由产品评估、来源级抽查与能力边界披露承接。

系统把“任务完成”定义为可重验的数据产品。每条正式数据都说明来源、处理过程、质量状态和不确定之处；收到反馈后，系统可以定位修正并形成可追溯的新版本。对照赛题的评价维度：来源可追溯性、清洗整合可靠性与输出格式可用性，已由第五章的案例与对照实验直接覆盖（其余一个维度——数据查找完备性——的衡量标准见 5.1 节）。

核心贡献总结：本系统展示了从任务事件、来源资产到发布回执的可检查证据链；其已验证范围是字节完整性、运行绑定和确定性检查规则，科学真实性与需求覆盖仍需来源级和任务级评估。

参考文献

- [1] LangChain. LangGraph: Orchestrate LLM agents as stateful graphs [OL]. <https://github.com/langchain-ai/langgraph>, 2025.
- [2] Wu Q., Bansal G., et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation [C/OL]. arXiv:2308.08155, 2023.
- [3] OpenAI. OpenAI Agents SDK: Lightweight agent harness [OL]. <https://openai.github.io/openai-agents-python/>, 2025.
- [4] Shankar S., et al. DocETL: A Deeply Optimized Declarative ETL System for Complex Data [C/OL]. arXiv:2410.12189, 2024.
- [5] Shankar S., et al. Palimpzest: Optimizing AI-Powered Data Pipelines with Adaptive Declarative Programming [C/OL]. arXiv:2405.14696, 2024.
- [6] Temporal Technologies. Temporal Design Patterns: Human Approval [OL]. <https://docs.temporal.io/develop/>, 2026-08 检索.
- [7] Qoder. 什么是 Qoder: 面向真实工作的 Agentic 平台 [OL]. <https://docs.qoder.com/zh/product-series/what-is-qoder>, 2026-09 检索.